Analyse von EAD-XML Daten des Kalliope Verbundkatalogs

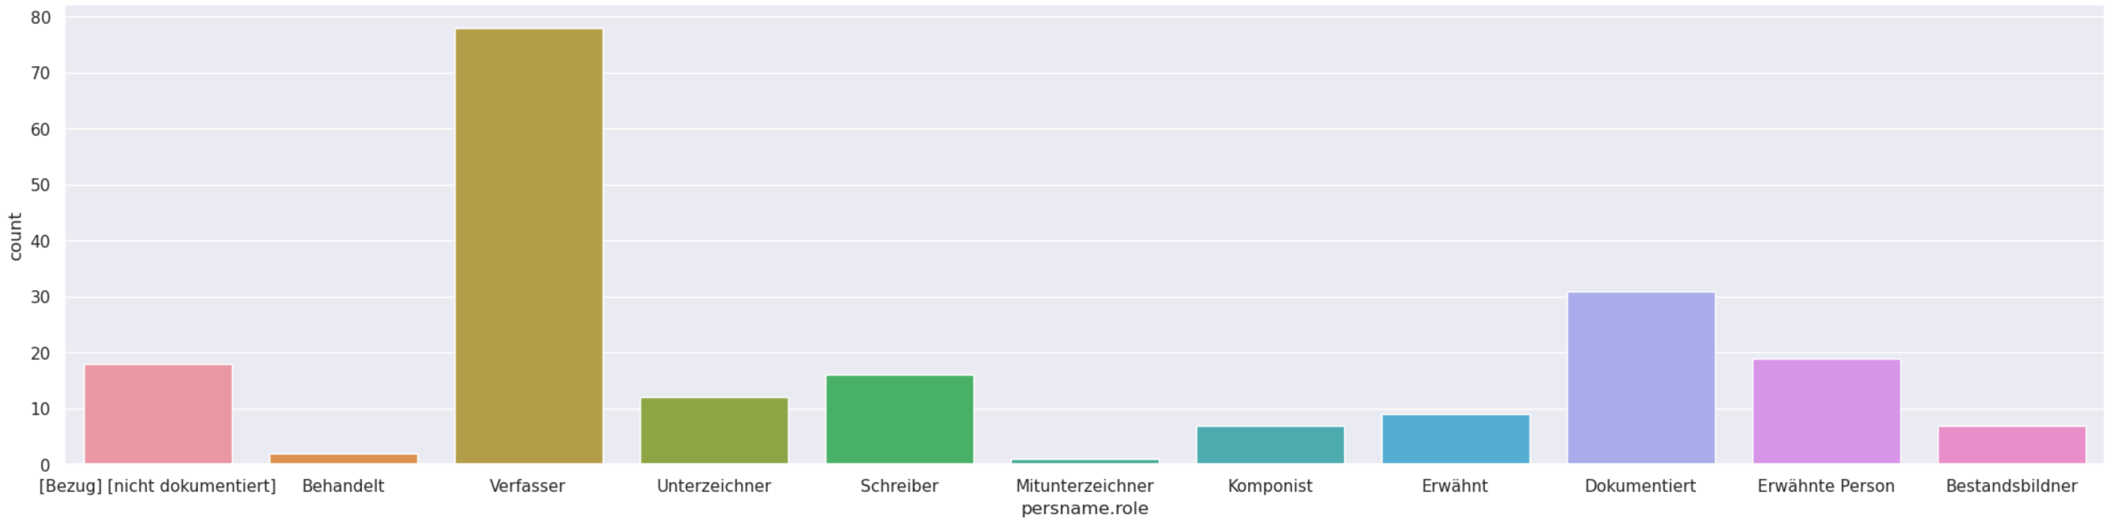

ZBIW Data Librarian 2022/2023, Modul 6, Projektarbeit, Katja Jana

Themen

- **Parsen von EAD-XML mit:**
  - Python Module BeautifulSoup
  - Catmandu
- **Kommandozeile**
- **Python in Jupyter Notebooks:**
  - CSV-Dateien mit Python Pandas und Visualisierung mittels Python

https://kalliope-verbund.info/: Nachweise von Archivalien aus Nachlassverzeichnissen und Nachlässen verschiedener kulturellen Institution und Gedächtnisorganisationen.

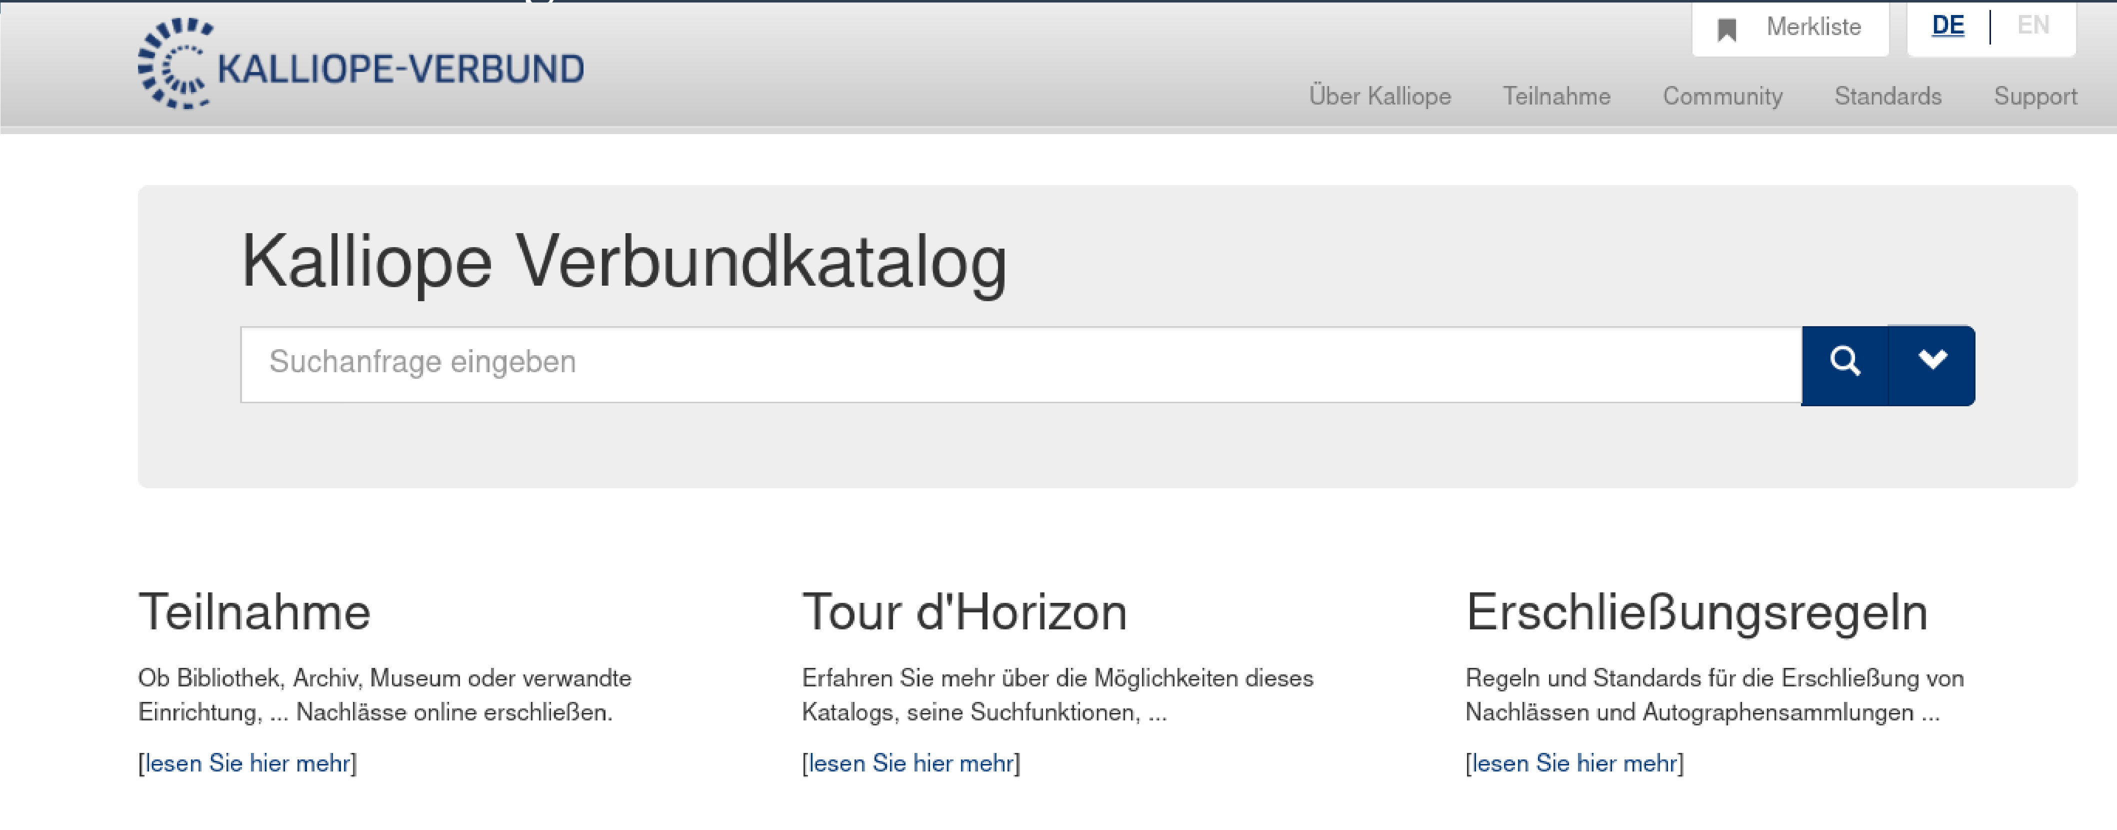

KALLIOPE-VERBUND

Merkliste DE | EN

Über Kalliope Teilnahme Community Standards Support

Kalliope Verbundkatalog

Suchanfrage eingeben

Teilnahme

Ob Bibliothek, Archiv, Museum oder verwandte Einrichtung, ... Nachlässe online erschließen.

[lesen Sie hier mehr]

Tour d'Horizon

Erfahren Sie mehr über die Möglichkeiten dieses Katalogs, seine Suchfunktionen, ...

[lesen Sie hier mehr]

Erschließungsregeln

Regeln und Standards für die Erschließung von Nachlässen und Autographensammlungen ...

[lesen Sie hier mehr]

https://kalliope-verbund.info/: Nachweise von Archivalien aus Nachlassverzeichnissen und Nachlässen verschiedener kulturellen Institution und Gedächtnisorganisationen.

- Retrokonversion Zentralkartei der Autographen zwischen 2001 und 2006: Bestände von nahezu 540 Institutionen

- Erschließungsplattform: momentan weisen circa 1000 Gedächtnisinstitutionen ihre Nachlässe und Autographen in Kalliope nach.

- Normdaten: Personen- und Organisationsdaten sind, wenn vorhanden, mit GND-Normdaten verknüpft.

Kalliope EAD-XML-Format

- **Der Anfang: aktueller Gesamtabzug der Kalliope-Datenbank: 11,0 GiB, 29.130 Dateien (von 1,6 KiB bis 178,2 MiB)**
- EAD-XML-Format: EAD-XML Standard legt die Kodierung von archivarischen Findbüchern fest
- Dokumentation: https://kalliope-verbund.info/files/480b012f45a0f002ec3095b6819ef8aea33078de.pdf

  https://www.loc.gov/ead/

Exemplarische Betrachtung von DE-1a_4273.xml mit Python library BeautifulSoup

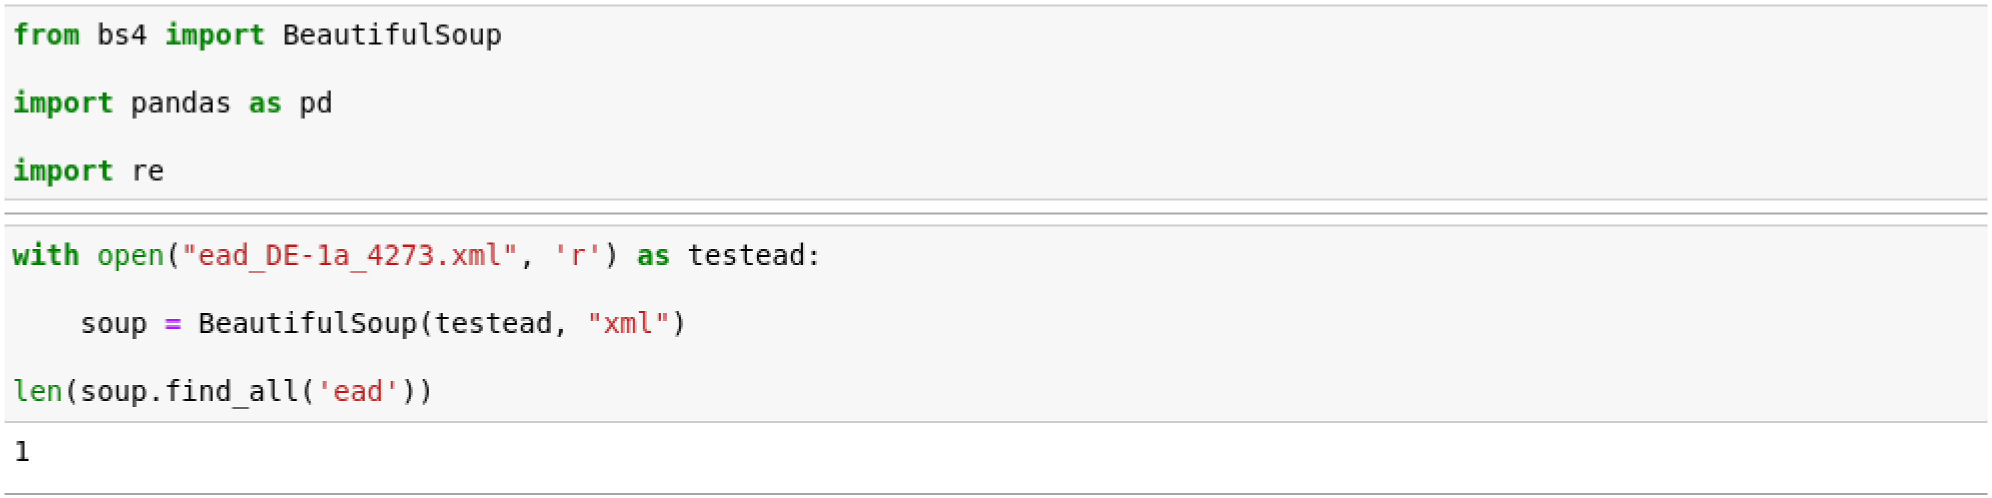

```
from bs4 import BeautifulSoup

import pandas as pd

import re
```

```
with open("ead_DE-1a_4273.xml", 'r') as testead:

    soup = BeautifulSoup(testead, "xml")

len(soup.find_all('ead'))
```

```
1
```

Exemplarische Betrachtung von DE-1a_4273.xml mit Python library BeautifulSoup

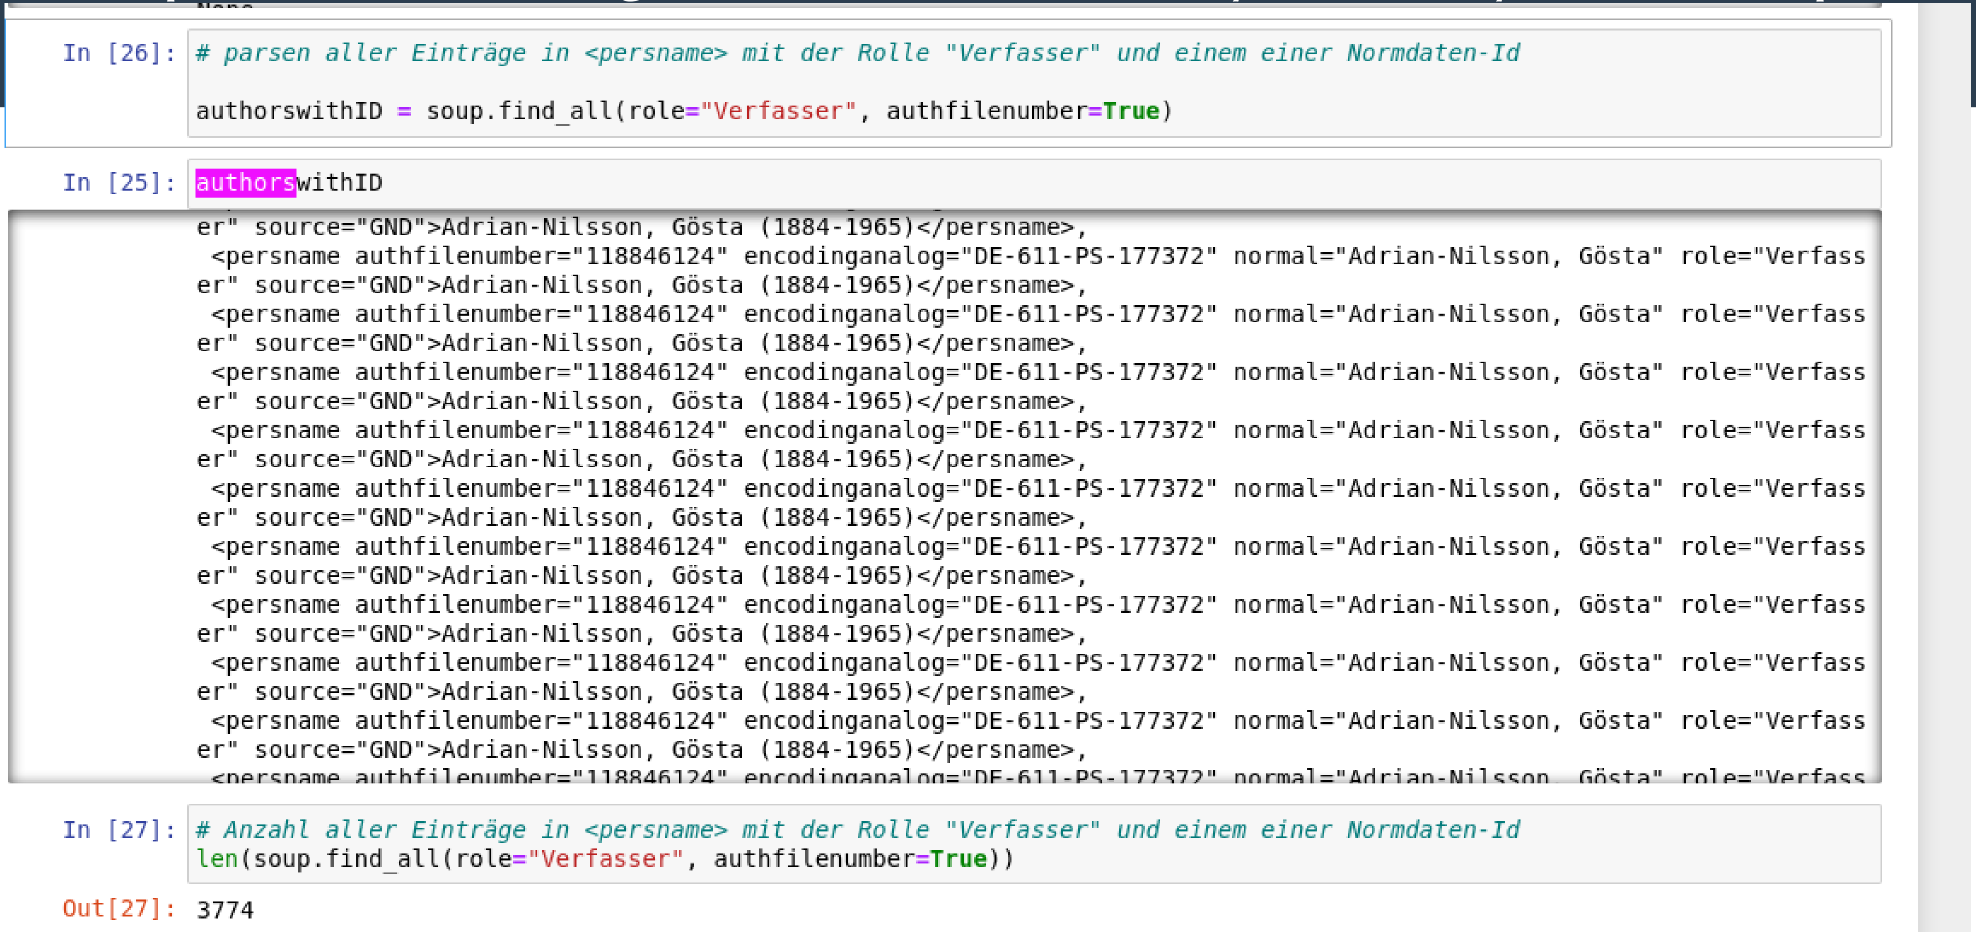

```
In [26]: # parsen aller Einträge in <persname> mit der Rolle "Verfasser" und einem einer Normdaten-Id

         authorswithID = soup.find_all(role="Verfasser", authfilenumber=True)

In [25]: authorswithID

         er" source="GND">Adrian-Nilsson, Gösta (1884-1965)</persname>,
          <persname authfilenumber="118846124" encodinganalog="DE-611-PS-177372" normal="Adrian-Nilsson, Gösta" role="Verfass
         er" source="GND">Adrian-Nilsson, Gösta (1884-1965)</persname>,
          <persname authfilenumber="118846124" encodinganalog="DE-611-PS-177372" normal="Adrian-Nilsson, Gösta" role="Verfass
         er" source="GND">Adrian-Nilsson, Gösta (1884-1965)</persname>,
          <persname authfilenumber="118846124" encodinganalog="DE-611-PS-177372" normal="Adrian-Nilsson, Gösta" role="Verfass
         er" source="GND">Adrian-Nilsson, Gösta (1884-1965)</persname>,
          <persname authfilenumber="118846124" encodinganalog="DE-611-PS-177372" normal="Adrian-Nilsson, Gösta" role="Verfass
         er" source="GND">Adrian-Nilsson, Gösta (1884-1965)</persname>,
          <persname authfilenumber="118846124" encodinganalog="DE-611-PS-177372" normal="Adrian-Nilsson, Gösta" role="Verfass
         er" source="GND">Adrian-Nilsson, Gösta (1884-1965)</persname>,
          <persname authfilenumber="118846124" encodinganalog="DE-611-PS-177372" normal="Adrian-Nilsson, Gösta" role="Verfass
         er" source="GND">Adrian-Nilsson, Gösta (1884-1965)</persname>,
          <persname authfilenumber="118846124" encodinganalog="DE-611-PS-177372" normal="Adrian-Nilsson, Gösta" role="Verfass
         er" source="GND">Adrian-Nilsson, Gösta (1884-1965)</persname>,
          <persname authfilenumber="118846124" encodinganalog="DE-611-PS-177372" normal="Adrian-Nilsson, Gösta" role="Verfass
         er" source="GND">Adrian-Nilsson, Gösta (1884-1965)</persname>,
          <persname authfilenumber="118846124" encodinganalog="DE-611-PS-177372" normal="Adrian-Nilsson, Gösta" role="Verfass
         er" source="GND">Adrian-Nilsson, Gösta (1884-1965)</persname>,
          <persname authfilenumber="118846124" encodinganalog="DE-611-PS-177372" normal="Adrian-Nilsson, Gösta" role="Verfass

In [27]: # Anzahl aller Einträge in <persname> mit der Rolle "Verfasser" und einem einer Normdaten-Id
         len(soup.find_all(role="Verfasser", authfilenumber=True))

Out[27]: 3774
```

Exemplarische Betrachtung von DE-1a_4273.xml mit Python library BeautifulSoup

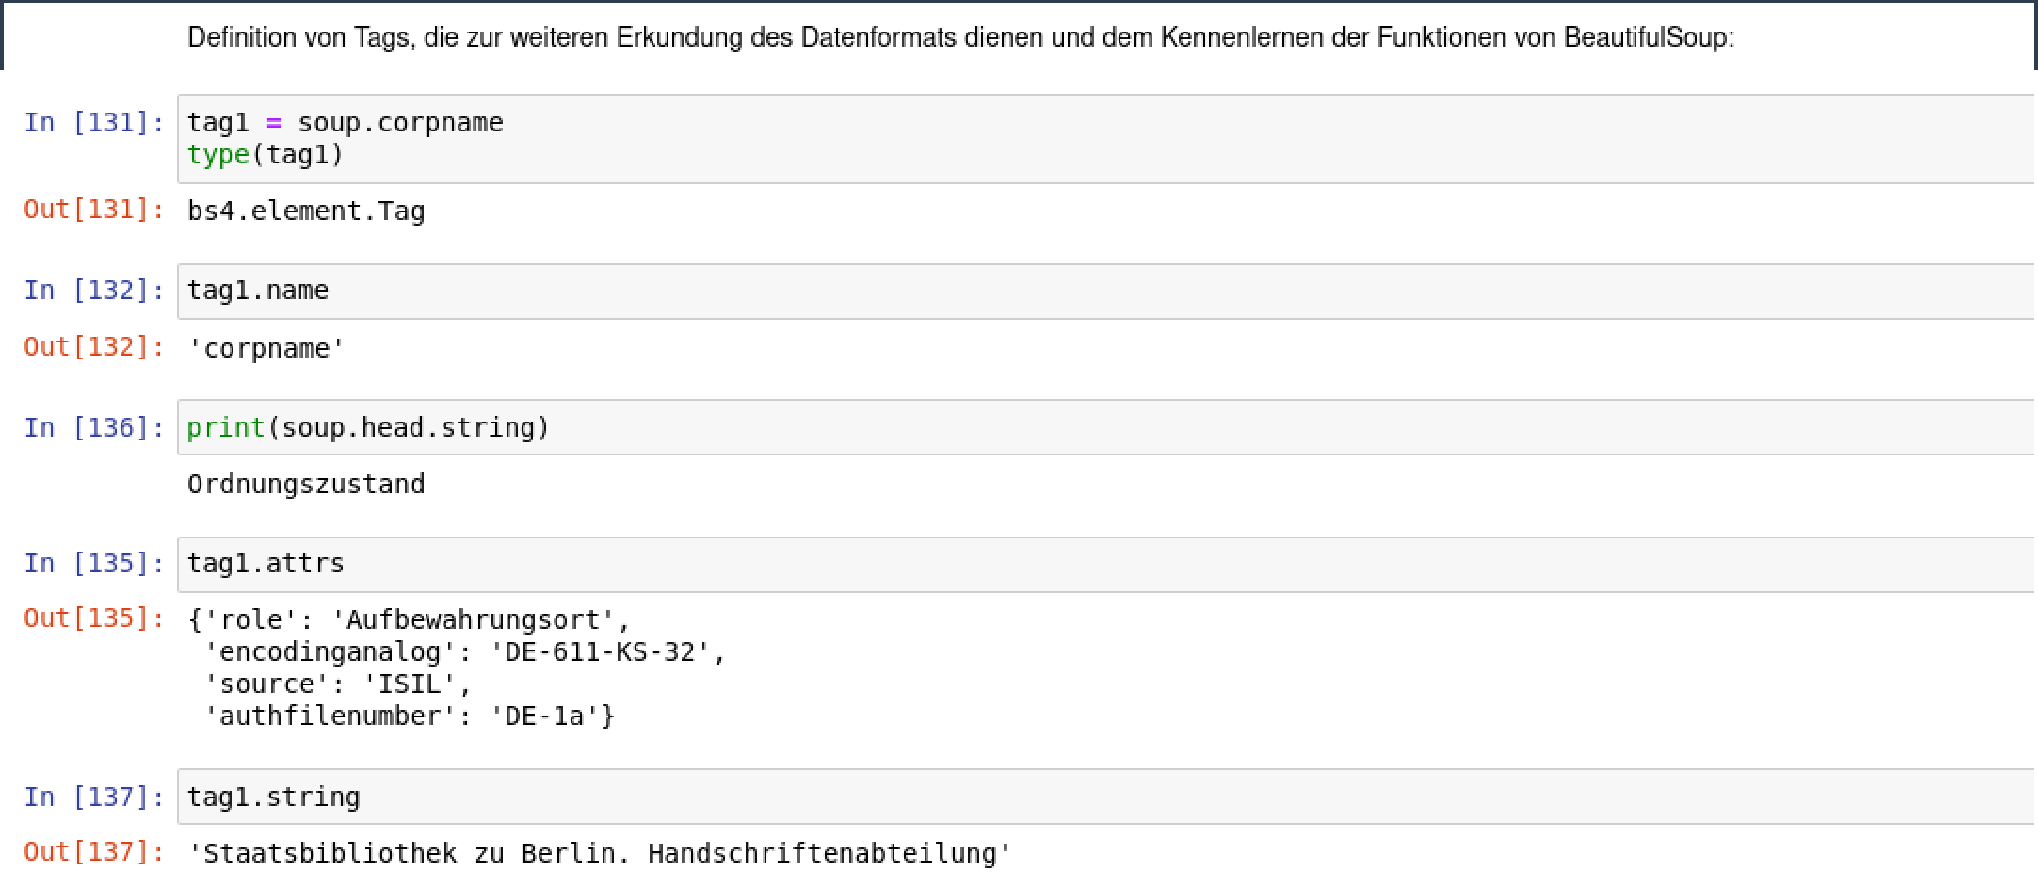
Definition von Tags, die zur weiteren Erkundung des Datenformats dienen und dem Kennenlernen der Funktionen von BeautifulSoup:

```
In [131]: tag1 = soup.corpname
          type(tag1)

Out[131]: bs4.element.Tag

In [132]: tag1.name

Out[132]: 'corpname'

In [136]: print(soup.head.string)

          Ordnungszustand

In [135]: tag1.attrs

Out[135]: {'role': 'Aufbewahrungsort',
           'encodinganalog': 'DE-611-KS-32',
           'source': 'ISIL',
           'authfilenumber': 'DE-1a'}

In [137]: tag1.string

Out[137]: 'Staatsbibliothek zu Berlin. Handschriftenabteilung'
```

Exemplarische Betrachtung von DE-1a_4273.xml mit Python library BeautifulSoup

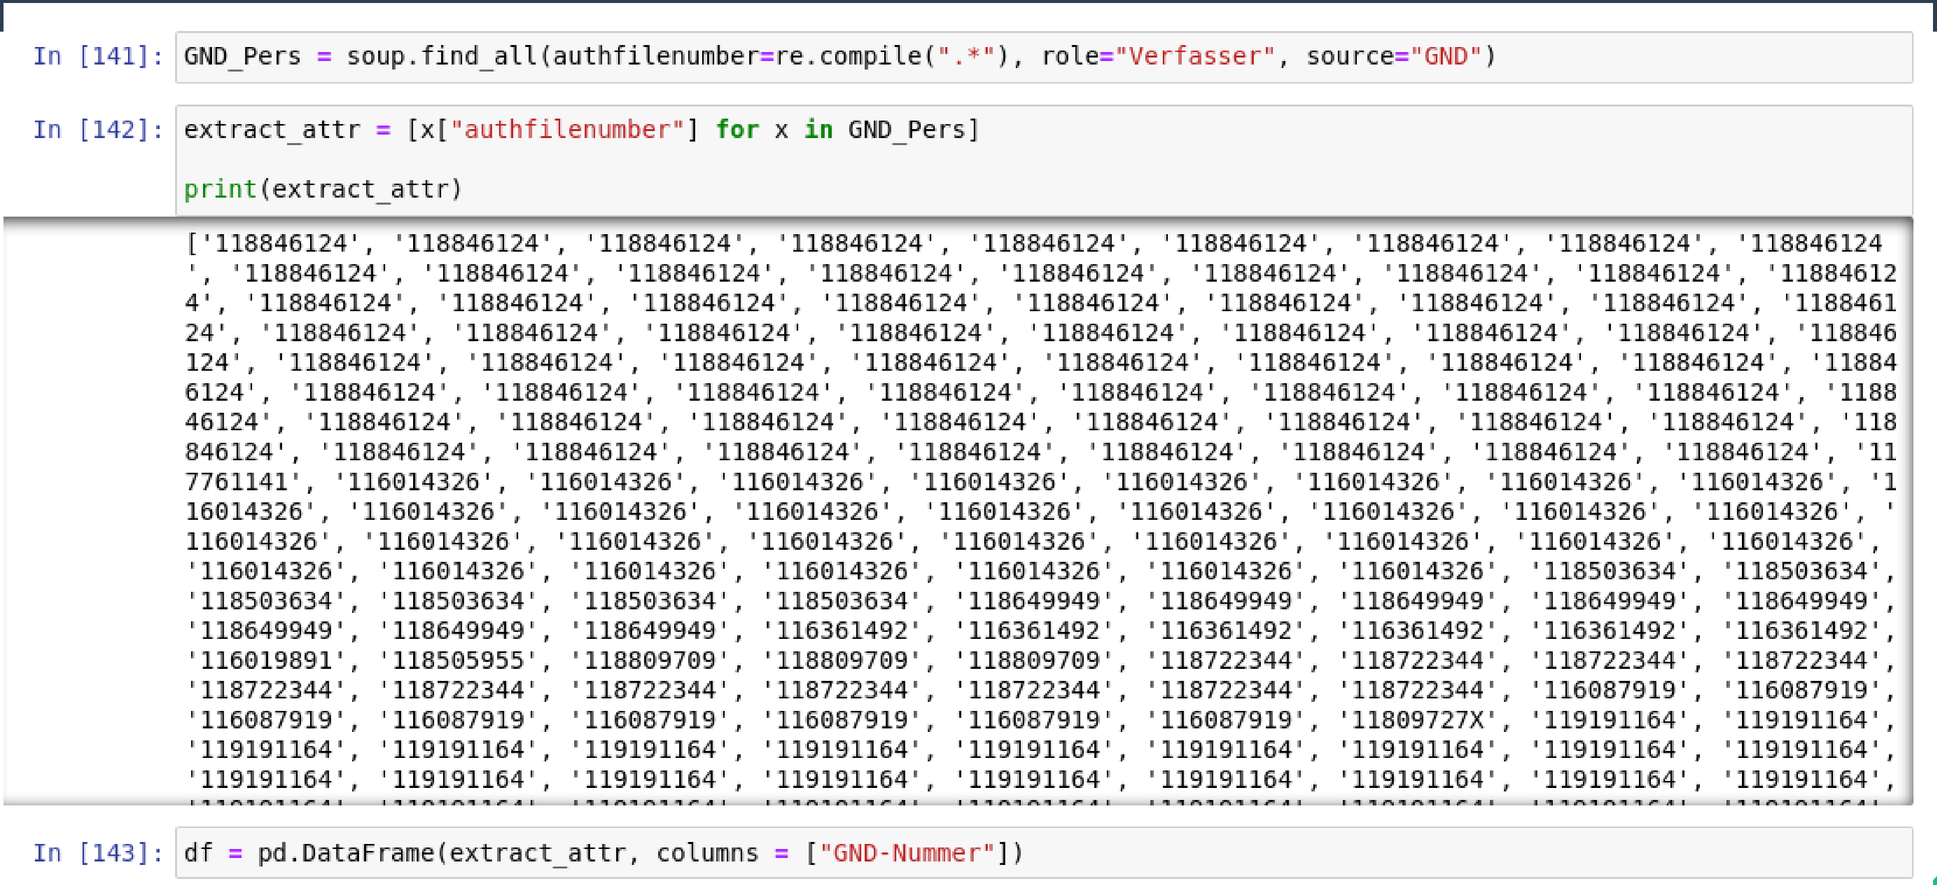

```
In [141]: GND_Pers = soup.find_all(authfilenumber=re.compile(".*"), role="Verfasser", source="GND")
```

```
In [142]: extract_attr = [x["authfilenumber"] for x in GND_Pers]

          print(extract_attr)
```

```
['118846124', '118846124', '118846124', '118846124', '118846124', '118846124', '118846124', '118846124', '118846124
', '118846124', '118846124', '118846124', '118846124', '118846124', '118846124', '118846124', '118846124', '11884612
4', '118846124', '118846124', '118846124', '118846124', '118846124', '118846124', '118846124', '118846124', '1188461
24', '118846124', '118846124', '118846124', '118846124', '118846124', '118846124', '118846124', '118846124', '118846
124', '118846124', '118846124', '118846124', '118846124', '118846124', '118846124', '118846124', '118846124', '11884
6124', '118846124', '118846124', '118846124', '118846124', '118846124', '118846124', '118846124', '118846124', '1188
46124', '118846124', '118846124', '118846124', '118846124', '118846124', '118846124', '118846124', '118846124', '118
846124', '118846124', '118846124', '118846124', '118846124', '118846124', '118846124', '118846124', '118846124', '11
7761141', '116014326', '116014326', '116014326', '116014326', '116014326', '116014326', '116014326', '116014326', '1
16014326', '116014326', '116014326', '116014326', '116014326', '116014326', '116014326', '116014326', '116014326', '
116014326', '116014326', '116014326', '116014326', '116014326', '116014326', '116014326', '116014326', '116014326',
'116014326', '116014326', '116014326', '116014326', '116014326', '116014326', '116014326', '118503634', '118503634',
'118503634', '118503634', '118503634', '118503634', '118649949', '118649949', '118649949', '118649949', '118649949',
'118649949', '118649949', '118649949', '116361492', '116361492', '116361492', '116361492', '116361492', '116361492',
'116019891', '118505955', '118809709', '118809709', '118809709', '118722344', '118722344', '118722344', '118722344',
'118722344', '118722344', '118722344', '118722344', '118722344', '118722344', '118722344', '116087919', '116087919',
'116087919', '116087919', '116087919', '116087919', '116087919', '116087919', '11809727X', '119191164', '119191164',
'119191164', '119191164', '119191164', '119191164', '119191164', '119191164', '119191164', '119191164', '119191164',
'119191164', '119191164', '119191164', '119191164', '119191164', '119191164', '119191164', '119191164', '119191164',
```

```
In [143]: df = pd.DataFrame(extract_attr, columns = ["GND-Nummer"])
```

Exemplarische Betrachtung von DE-1a_4273.xml mit Python library BeautifulSoup

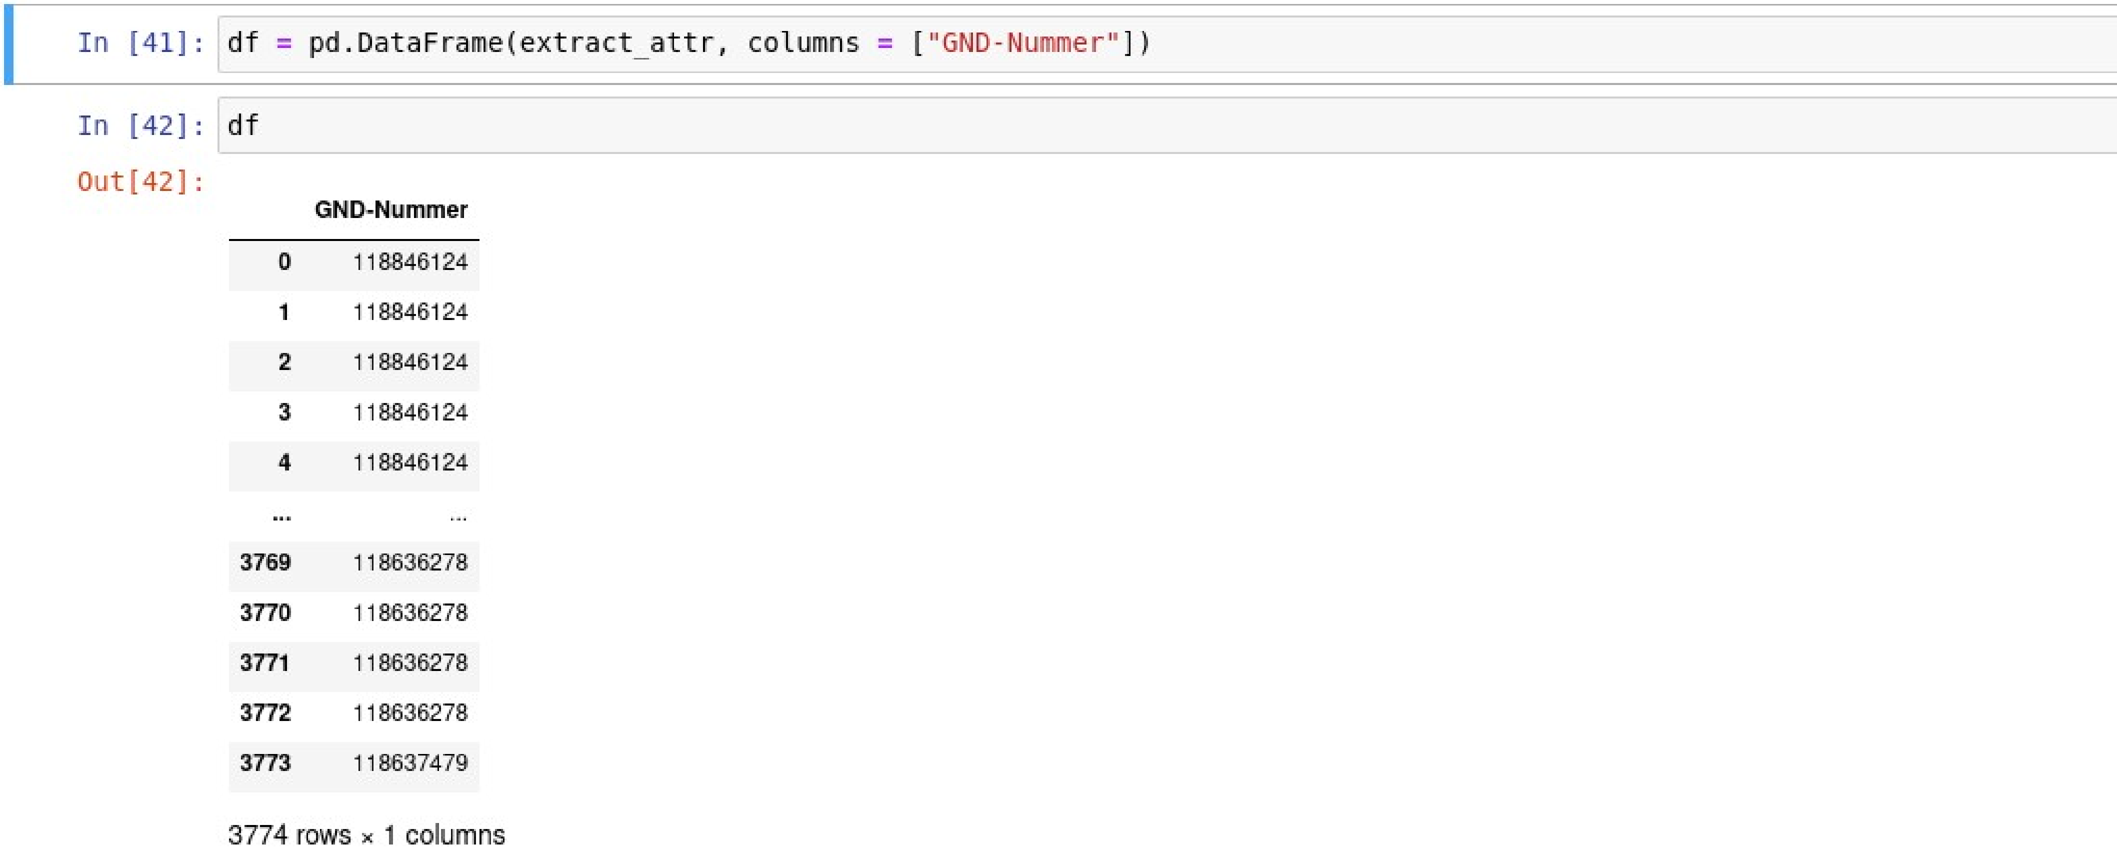

```
In [41]: df = pd.DataFrame(extract_attr, columns = ["GND-Nummer"])

In [42]: df

Out[42]:
```

	GND-Nummer
0	118846124
1	118846124
2	118846124
3	118846124
4	118846124
...	...
3769	118636278
3770	118636278
3771	118636278
3772	118636278
3773	118637479

3774 rows × 1 columns

Einlesen des mehrere EAD-XML Dateien mit Python library BeautifulSoup

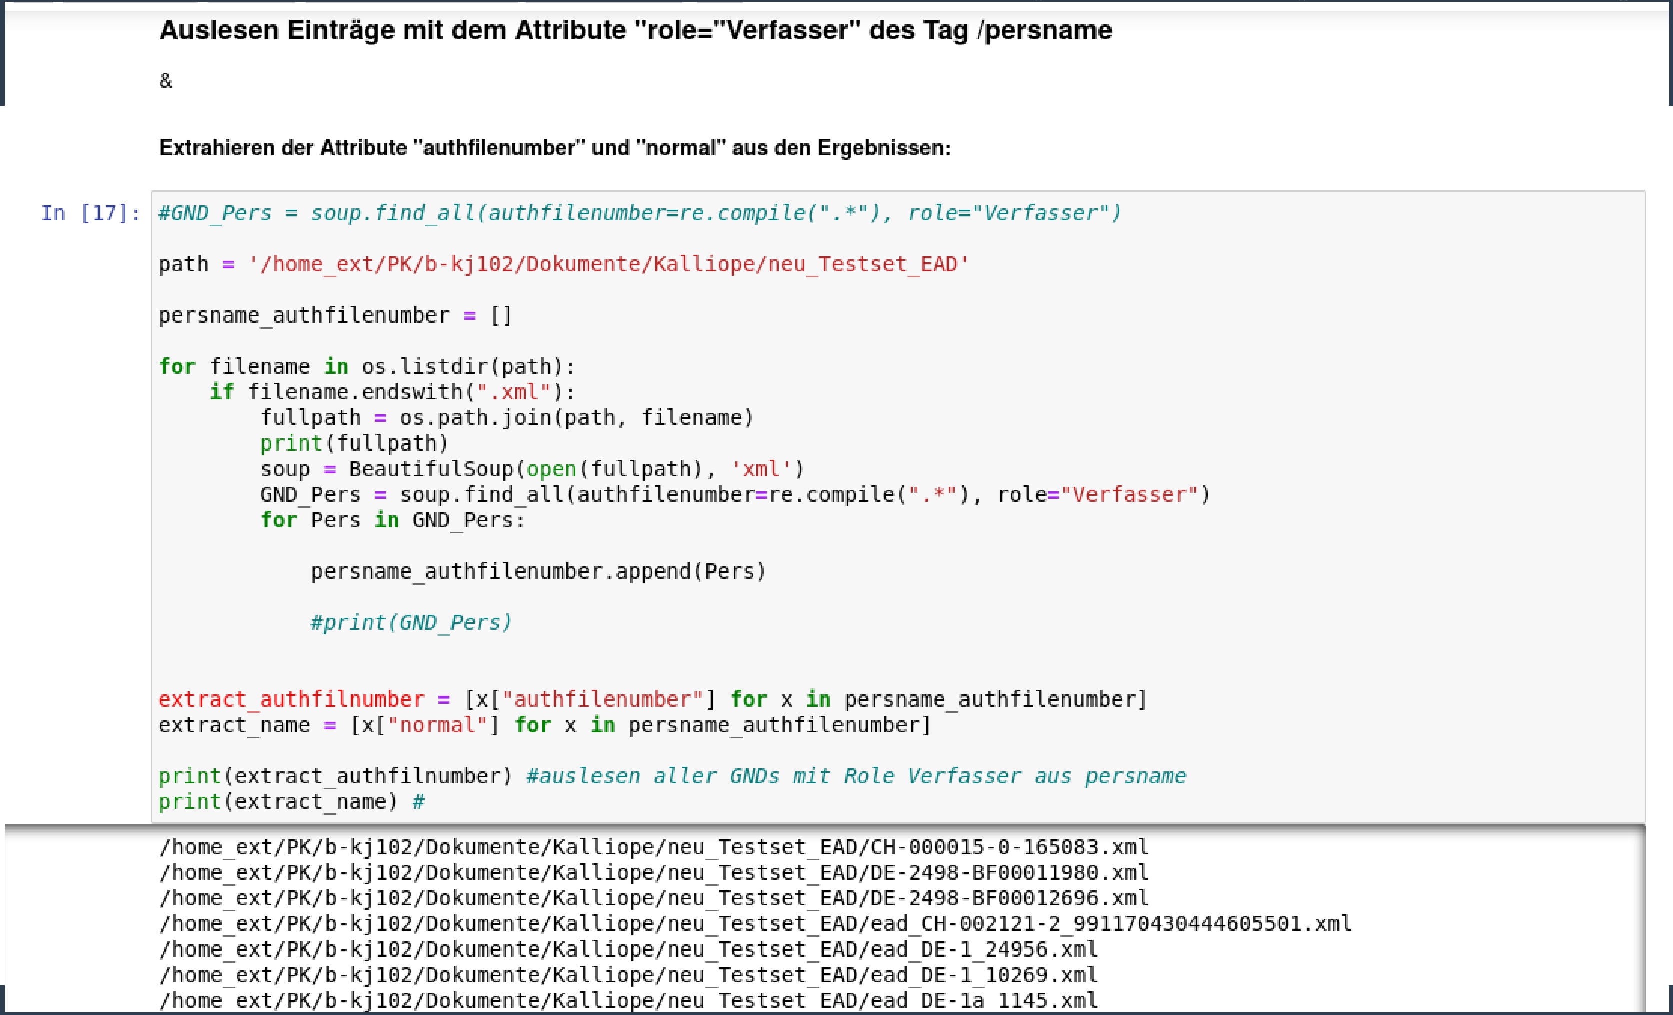

Auslesen Einträge mit dem Attribute "role="Verfasser" des Tag /persname

&

Extrahieren der Attribute "authfilenumber" und "normal" aus den Ergebnissen:

```
In [17]: #GND_Pers = soup.find_all(authfilenumber=re.compile(".*"), role="Verfasser")

path = '/home_ext/PK/b-kj102/Dokumente/Kalliope/neu_Testset_EAD'

persname_authfilenumber = []

for filename in os.listdir(path):
    if filename.endswith(".xml"):
        fullpath = os.path.join(path, filename)
        print(fullpath)
        soup = BeautifulSoup(open(fullpath), 'xml')
        GND_Pers = soup.find_all(authfilenumber=re.compile(".*"), role="Verfasser")
        for Pers in GND_Pers:

            persname_authfilenumber.append(Pers)

            #print(GND_Pers)


extract_authfilnumber = [x["authfilenumber"] for x in persname_authfilenumber]
extract_name = [x["normal"] for x in persname_authfilenumber]

print(extract_authfilnumber) #auslesen aller GNDs mit Role Verfasser aus persname
print(extract_name) #
```

```
/home_ext/PK/b-kj102/Dokumente/Kalliope/neu_Testset_EAD/CH-000015-0-165083.xml
/home_ext/PK/b-kj102/Dokumente/Kalliope/neu_Testset_EAD/DE-2498-BF00011980.xml
/home_ext/PK/b-kj102/Dokumente/Kalliope/neu_Testset_EAD/DE-2498-BF00012696.xml
/home_ext/PK/b-kj102/Dokumente/Kalliope/neu_Testset_EAD/ead_CH-002121-2_991170430444605501.xml
/home_ext/PK/b-kj102/Dokumente/Kalliope/neu_Testset_EAD/ead_DE-1_24956.xml
/home_ext/PK/b-kj102/Dokumente/Kalliope/neu_Testset_EAD/ead_DE-1_10269.xml
/home_ext/PK/b-kj102/Dokumente/Kalliope/neu_Testset_EAD/ead_DE-1a_1145.xml
```

Data Toolkit Catmandu

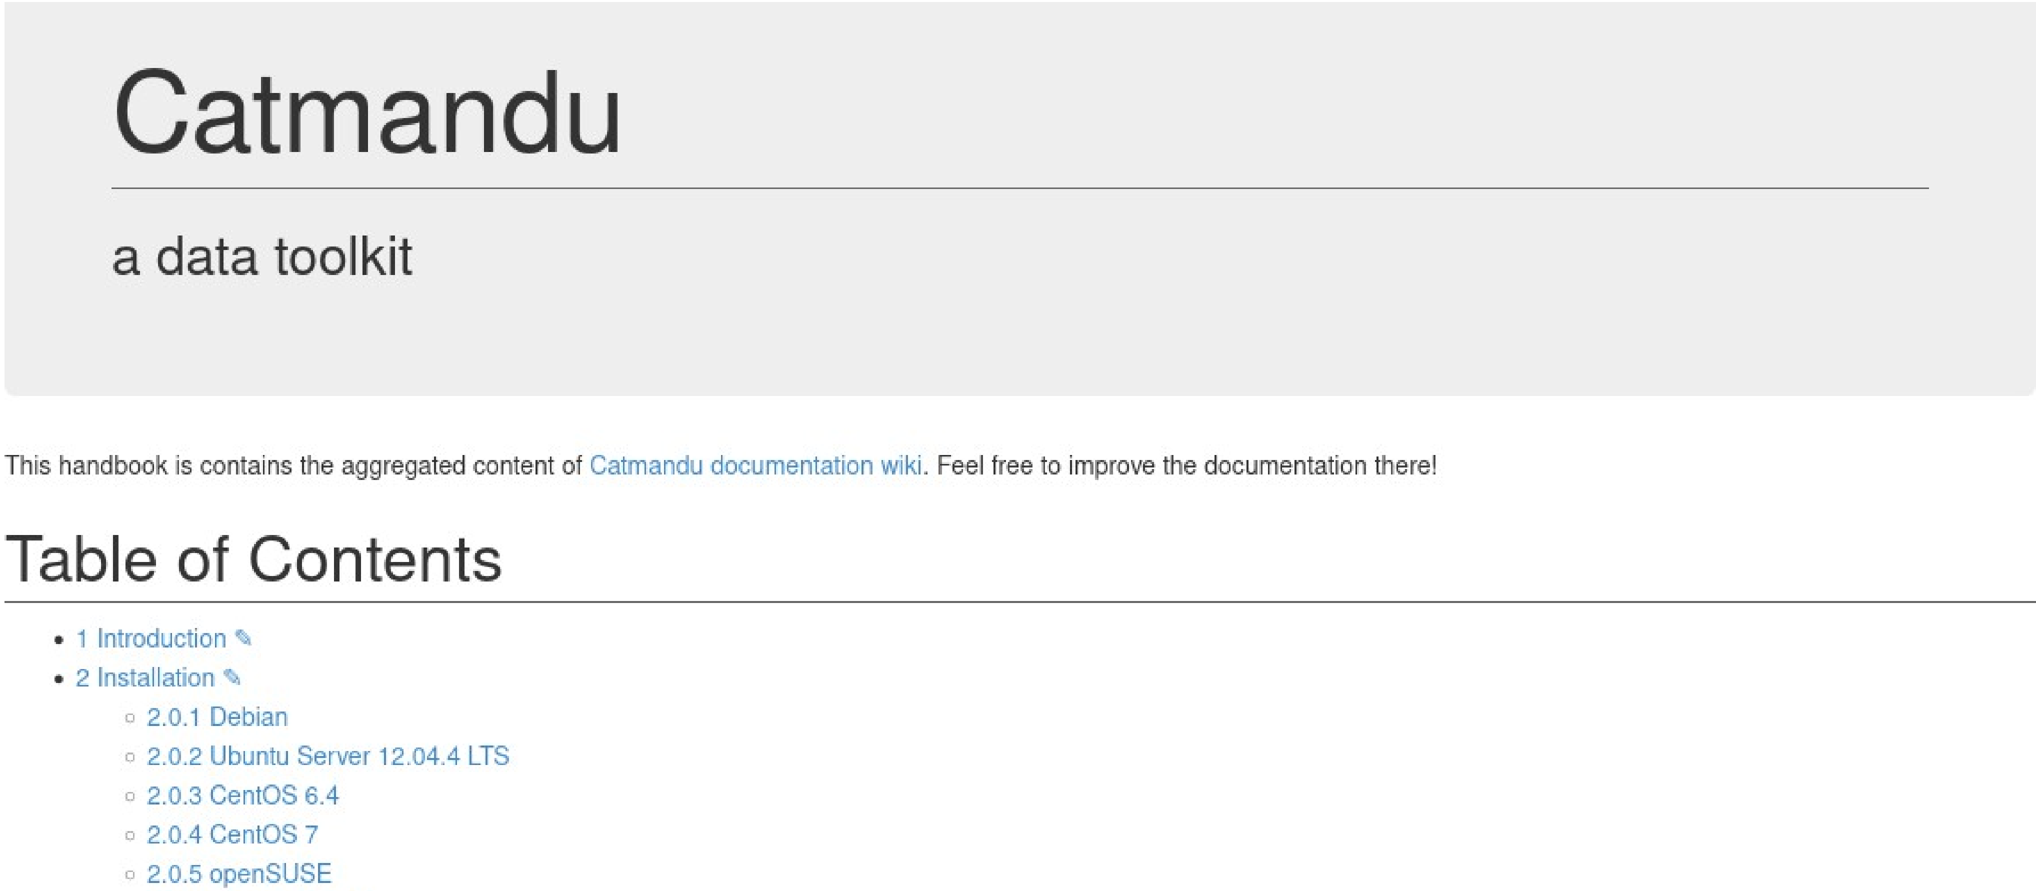

Catmandu

a data toolkit

This handbook is contains the aggregated content of Catmandu documentation wiki. Feel free to improve the documentation there!

Table of Contents

Data Toolkit Catmandu – Skript zum Parsen der Attribute in >persname<

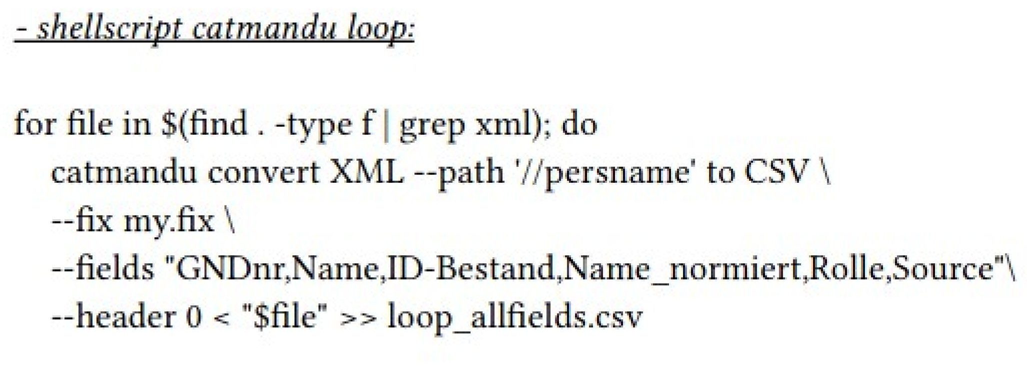

- shellscript catmandu loop:

```
for file in $(find . -type f | grep xml); do
    catmandu convert XML --path '//persname' to CSV \
    --fix my.fix \
    --fields "GNDnr,Name,ID-Bestand,Name_normiert,Rolle,Source"\
    --header 0 < "$file" >> loop_allfields.csv
```

Data Toolkit Catmandu – Skript zum Parsen der Attribute in <persname>

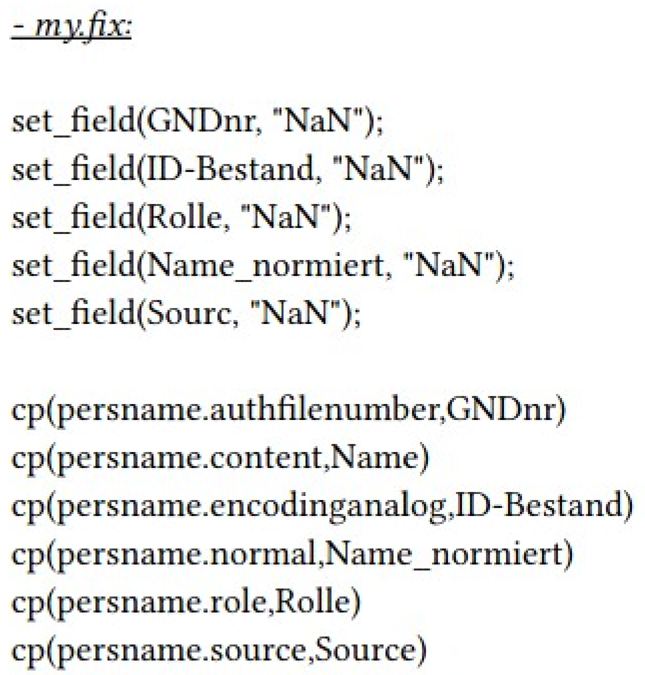

- my.fix:

```
set_field(GNDnr, "NaN");
set_field(ID-Bestand, "NaN");
set_field(Rolle, "NaN");
set_field(Name_normiert, "NaN");
set_field(Sourc, "NaN");

cp(persname.authfilenumber,GNDnr)
cp(persname.content,Name)
cp(persname.encodinganalog,ID-Bestand)
cp(persname.normal,Name_normiert)
cp(persname.role,Rolle)
cp(persname.source,Source)
```

Kommandozeile: Mittels uniq und grep die Daten bereinigen

```
$ sort loop_allfields.csv | uniq > uniqloop_allfields.csv
```

```
$ grep -E  "(^[0-9],{8,11})" uniqloop_allfields.csv > uniqloop_allfields_cleangnd.csv
```

Kommandozeile: Mittels uniq und grep die Daten bereinigen

- **In aDIS/BMS, auf dem die Kalliope Datenbank beruht, sind manche Normdaten fehlerhaft zugewiesen werden, z.B. stehen an manchen Stellen Orcid- statt GND-Ids,**

- **Bereinigte Daten: Anzahl der Einträge von 8538251 auf 1743865 (sort | uniq) auf 817629 (grep). Dabei wurden auch fehlerhaft gelieferte Daten ausgefiltert, wo GND-Ids als Links eingetragen waren. Bei Gelegenheit müsste hier nochmal feiner gefiltert werden. Daher erklärt sich die hohe Anzahl von circa 200.000 entfernten Einträgen.**

<persname> in Pandas DataFrame (vor grep)

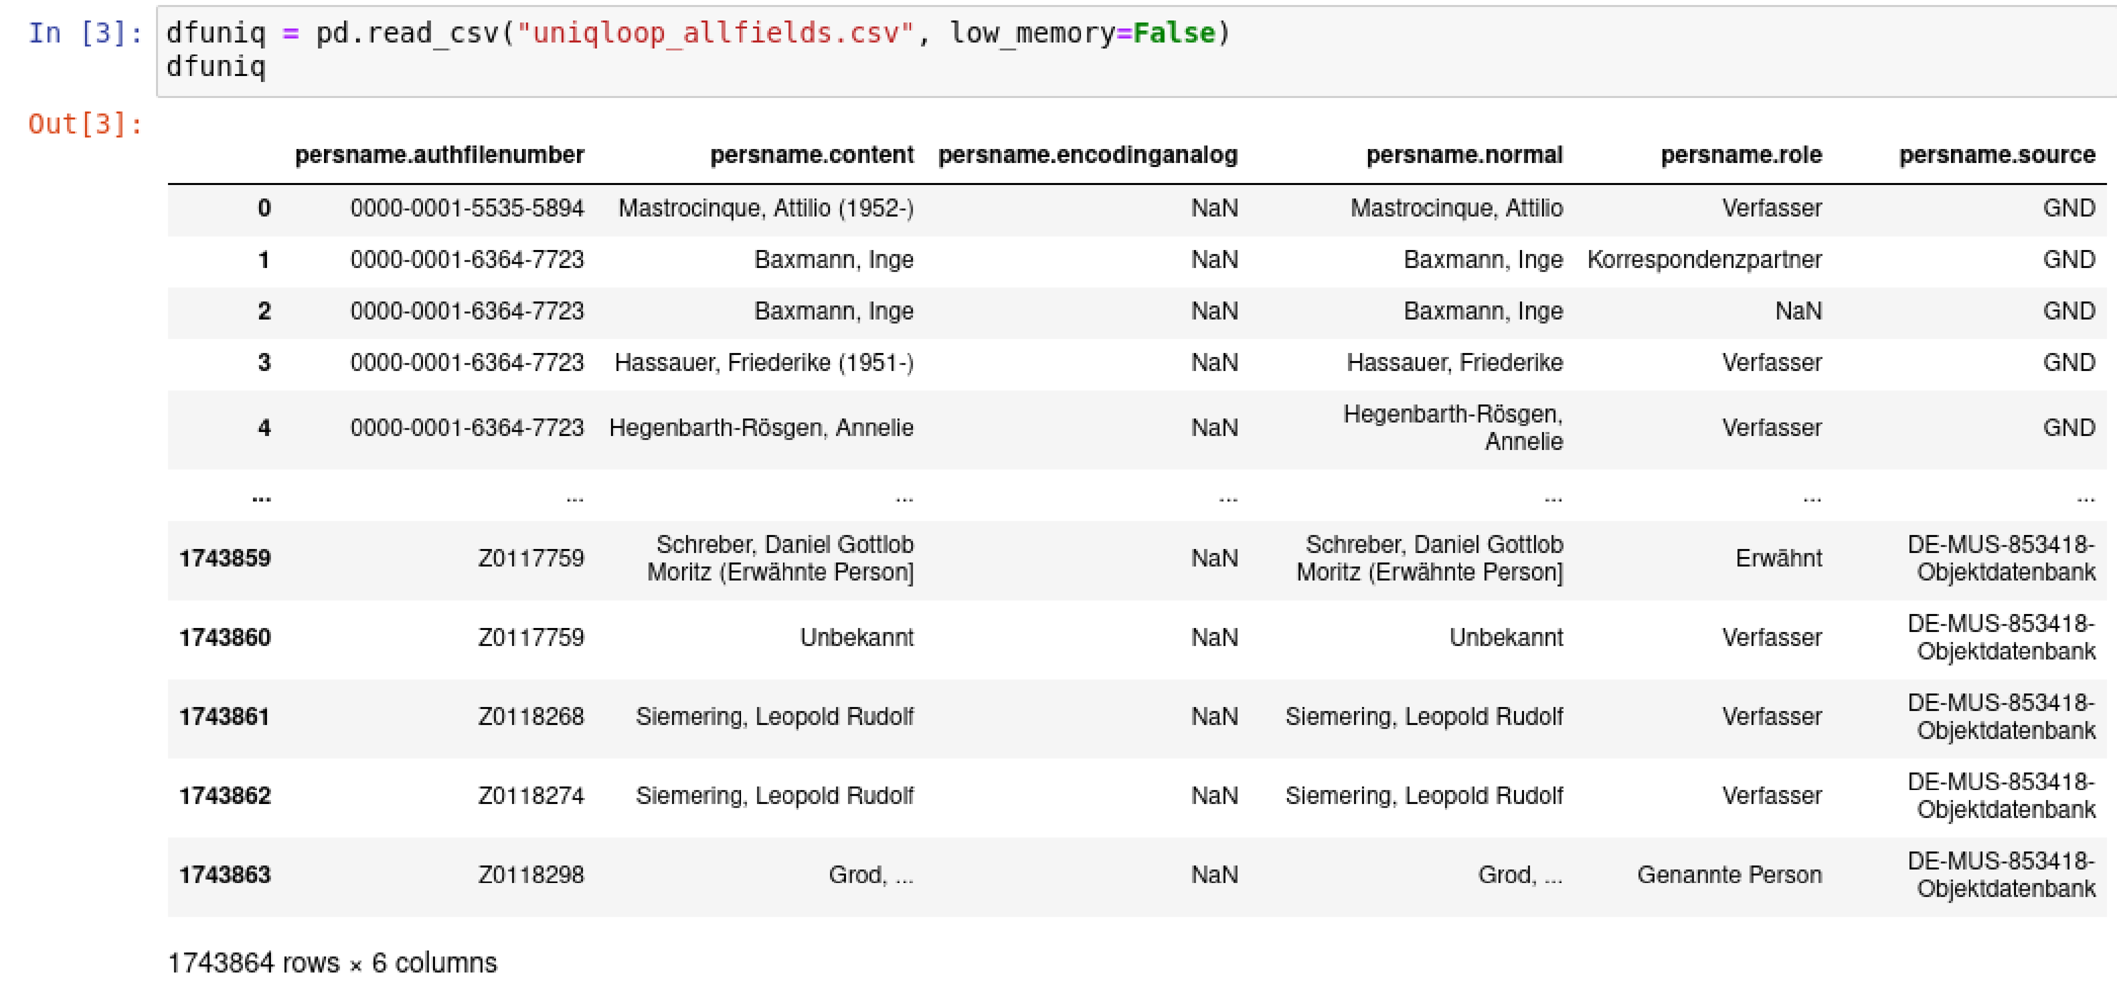

```
In [3]: dfuniq = pd.read_csv("uniqloop_allfields.csv", low_memory=False)
        dfuniq
```

Out[3]:

	persname.authfilenumber	persname.content	persname.encodinganalog	persname.normal	persname.role	persname.source
0	0000-0001-5535-5894	Mastrocinque, Attilio (1952-)	NaN	Mastrocinque, Attilio	Verfasser	GND
1	0000-0001-6364-7723	Baxmann, Inge	NaN	Baxmann, Inge	Korrespondenzpartner	GND
2	0000-0001-6364-7723	Baxmann, Inge	NaN	Baxmann, Inge	NaN	GND
3	0000-0001-6364-7723	Hassauer, Friederike (1951-)	NaN	Hassauer, Friederike	Verfasser	GND
4	0000-0001-6364-7723	Hegenbarth-Rösgen, Annelie	NaN	Hegenbarth-Rösgen, Annelie	Verfasser	GND
...	...	...	...	...	...	...
1743859	Z0117759	Schreber, Daniel Gottlob Moritz (Erwähnte Person]	NaN	Schreber, Daniel Gottlob Moritz (Erwähnte Person]	Erwähnt	DE-MUS-853418-Objektdatenbank
1743860	Z0117759	Unbekannt	NaN	Unbekannt	Verfasser	DE-MUS-853418-Objektdatenbank
1743861	Z0118268	Siemering, Leopold Rudolf	NaN	Siemering, Leopold Rudolf	Verfasser	DE-MUS-853418-Objektdatenbank
1743862	Z0118274	Siemering, Leopold Rudolf	NaN	Siemering, Leopold Rudolf	Verfasser	DE-MUS-853418-Objektdatenbank
1743863	Z0118298	Grod, ...	NaN	Grod, ...	Genannte Person	DE-MUS-853418-Objektdatenbank

1743864 rows × 6 columns

>persname< in Pandas DataFrame (vor grep): sources Normdaten

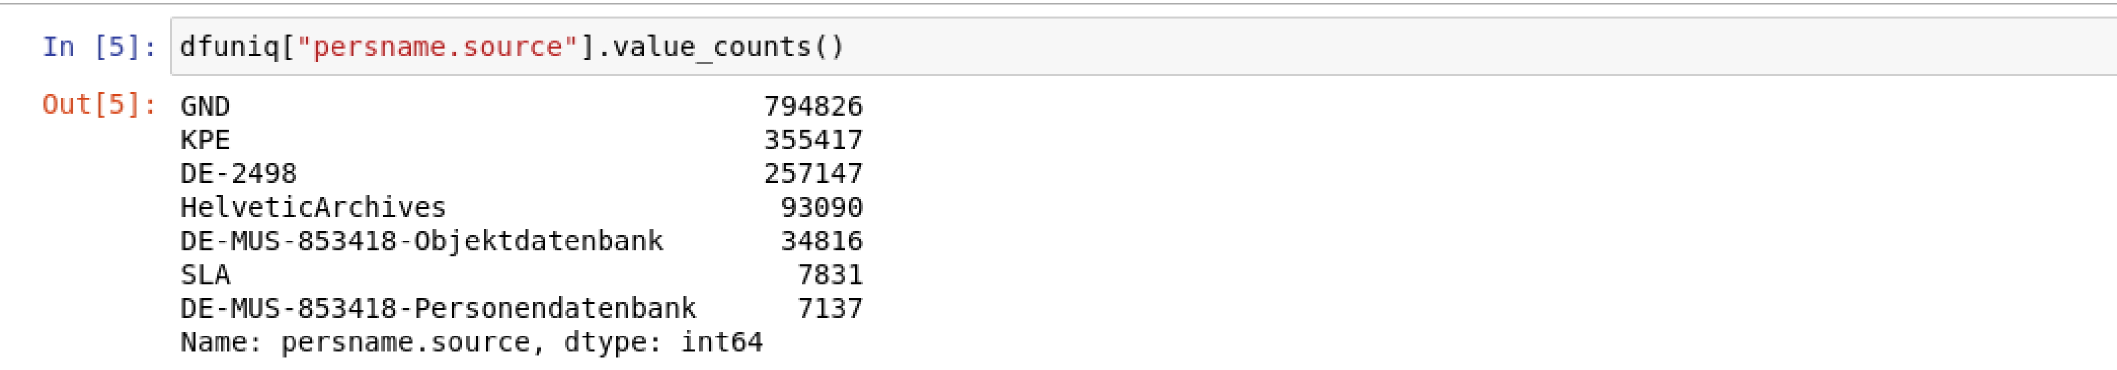

```
In [5]: dfuniq["persname.source"].value_counts()

Out[5]: GND                                  794826
        KPE                                  355417
        DE-2498                              257147
        HelveticArchives                      93090
        DE-MUS-853418-Objektdatenbank         34816
        SLA                                    7831
        DE-MUS-853418-Personendatenbank        7137
        Name: persname.source, dtype: int64
```

>persname< in Pandas DataFrame (vor grep): roles

```
In [13]: dfuniq["persname.role"].value_counts().nlargest(n=15).plot(kind="bar", color = 'dodgerblue')
Out[13]: <AxesSubplot:>
```

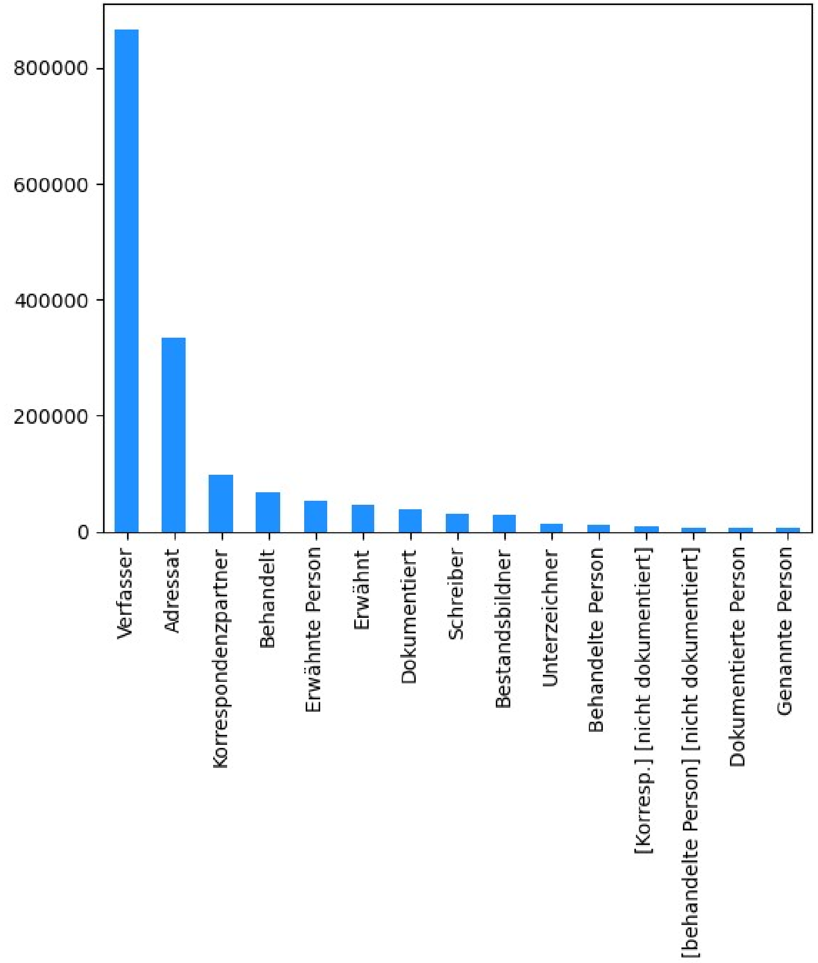

>persname< in Pandas DataFrame (vor grep): Namen

```
In [14]: dfuniq["persname.normal"].value_counts().nlargest(n=15).plot(kind="bar", color='olive')

Out[14]: <AxesSubplot:>
```

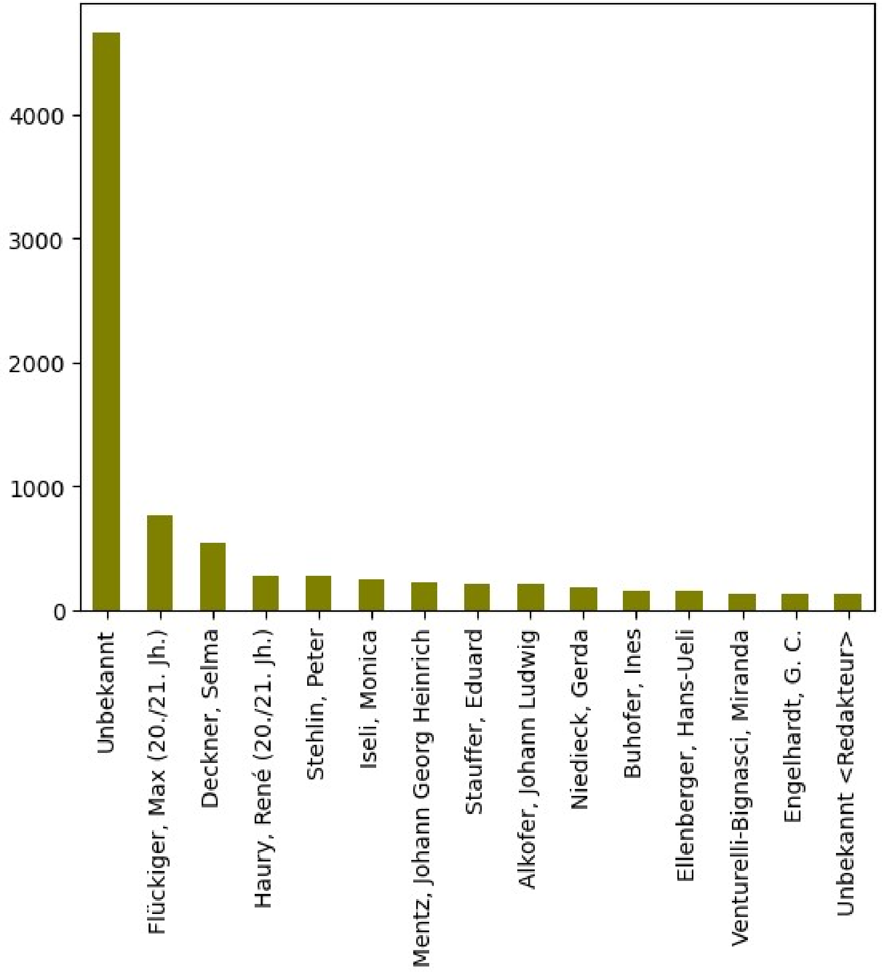

>persname< in Pandas DataFrame (nach grep, bereinigte Ids)

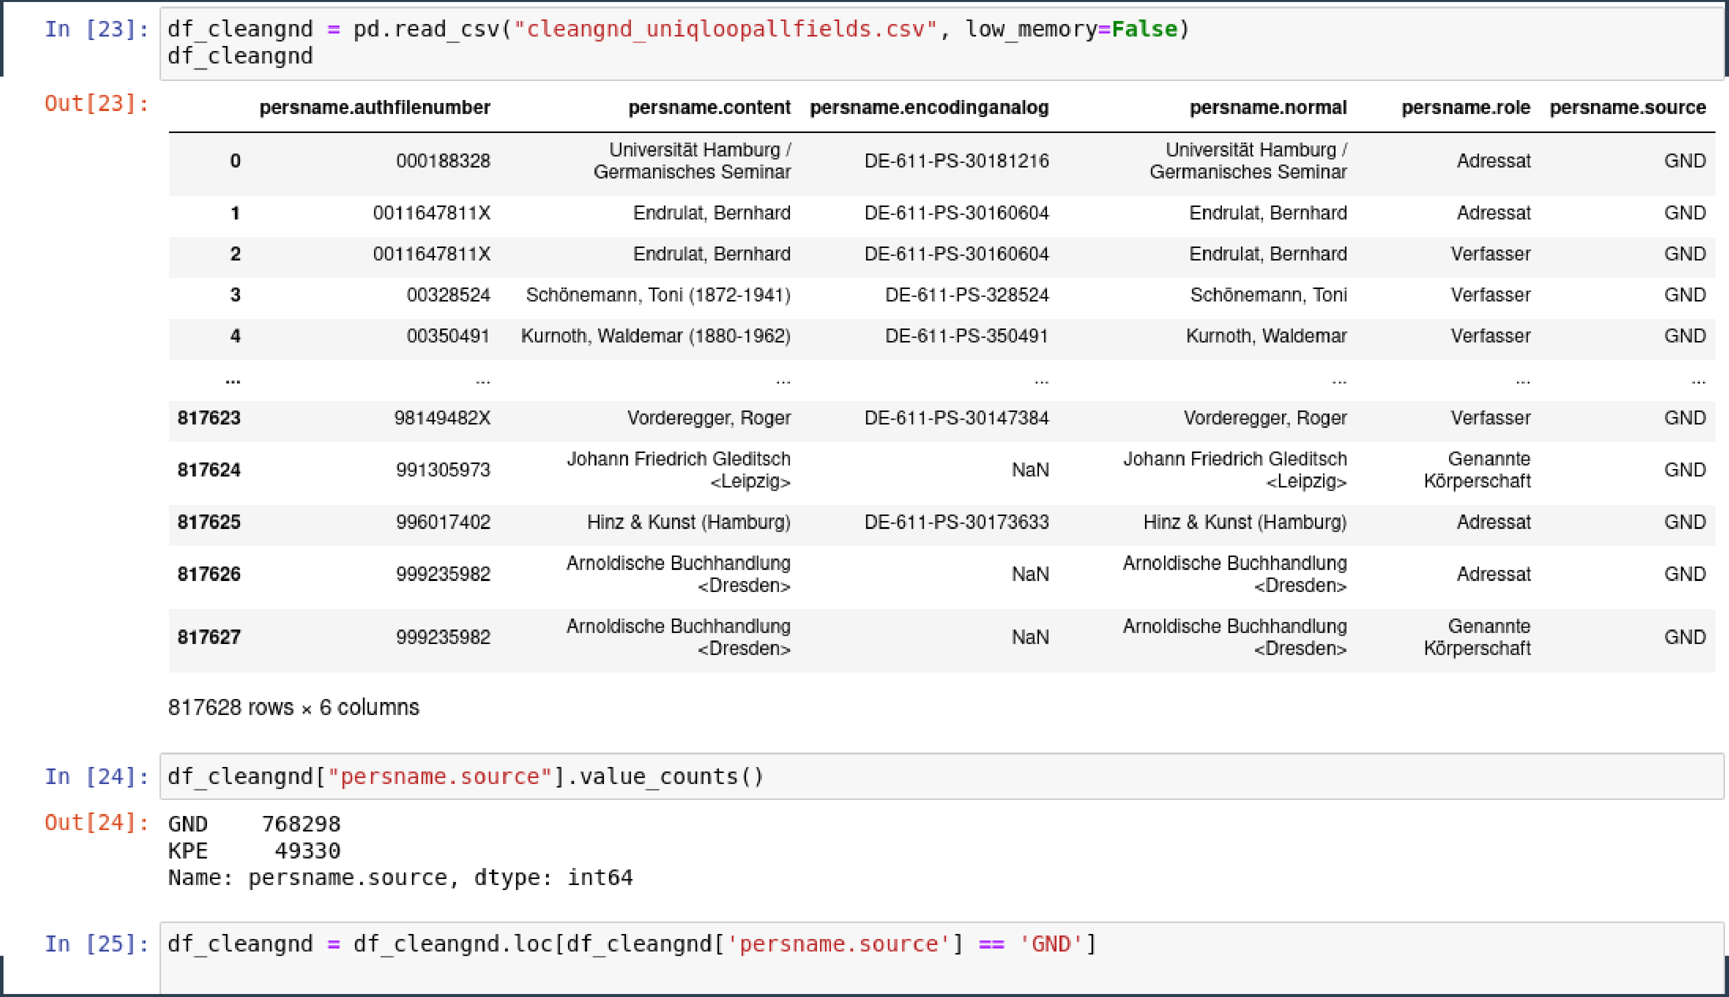

```
In [23]: df_cleangnd = pd.read_csv("cleangnd_uniqloopallfields.csv", low_memory=False)
         df_cleangnd
```

Out[23]:

	persname.authfilenumber	persname.content	persname.encodinganalog	persname.normal	persname.role	persname.source
0	000188328	Universität Hamburg / Germanisches Seminar	DE-611-PS-30181216	Universität Hamburg / Germanisches Seminar	Adressat	GND
1	0011647811X	Endrulat, Bernhard	DE-611-PS-30160604	Endrulat, Bernhard	Adressat	GND
2	0011647811X	Endrulat, Bernhard	DE-611-PS-30160604	Endrulat, Bernhard	Verfasser	GND
3	00328524	Schönemann, Toni (1872-1941)	DE-611-PS-328524	Schönemann, Toni	Verfasser	GND
4	00350491	Kurnoth, Waldemar (1880-1962)	DE-611-PS-350491	Kurnoth, Waldemar	Verfasser	GND
...	...	...	...	...	...	...
817623	98149482X	Vorderegger, Roger	DE-611-PS-30147384	Vorderegger, Roger	Verfasser	GND
817624	991305973	Johann Friedrich Gleditsch <Leipzig>	NaN	Johann Friedrich Gleditsch <Leipzig>	Genannte Körperschaft	GND
817625	996017402	Hinz & Kunst (Hamburg)	DE-611-PS-30173633	Hinz & Kunst (Hamburg)	Adressat	GND
817626	999235982	Arnoldische Buchhandlung <Dresden>	NaN	Arnoldische Buchhandlung <Dresden>	Adressat	GND
817627	999235982	Arnoldische Buchhandlung <Dresden>	NaN	Arnoldische Buchhandlung <Dresden>	Genannte Körperschaft	GND

817628 rows × 6 columns

```
In [24]: df_cleangnd["persname.source"].value_counts()

Out[24]: GND    768298
         KPE     49330
         Name: persname.source, dtype: int64

In [25]: df_cleangnd = df_cleangnd.loc[df_cleangnd['persname.source'] == 'GND']
```

<persname> in Pandas DataFrame (nach grep, bereinigte Ids): Erstellen eines neuen DataFrames für die vier häufigst vergebenen persname.role

- Zunächst vier einzelne DataFrames für persname.rolle:
  Verfasser, Adressat,
  Korrespondenzpartner, Behandelt
- Filtern der jeweils alle vielfach vorkommenden GND-Nummern
- Mit .concat konnten diese vier DataFrames zusammengeführen

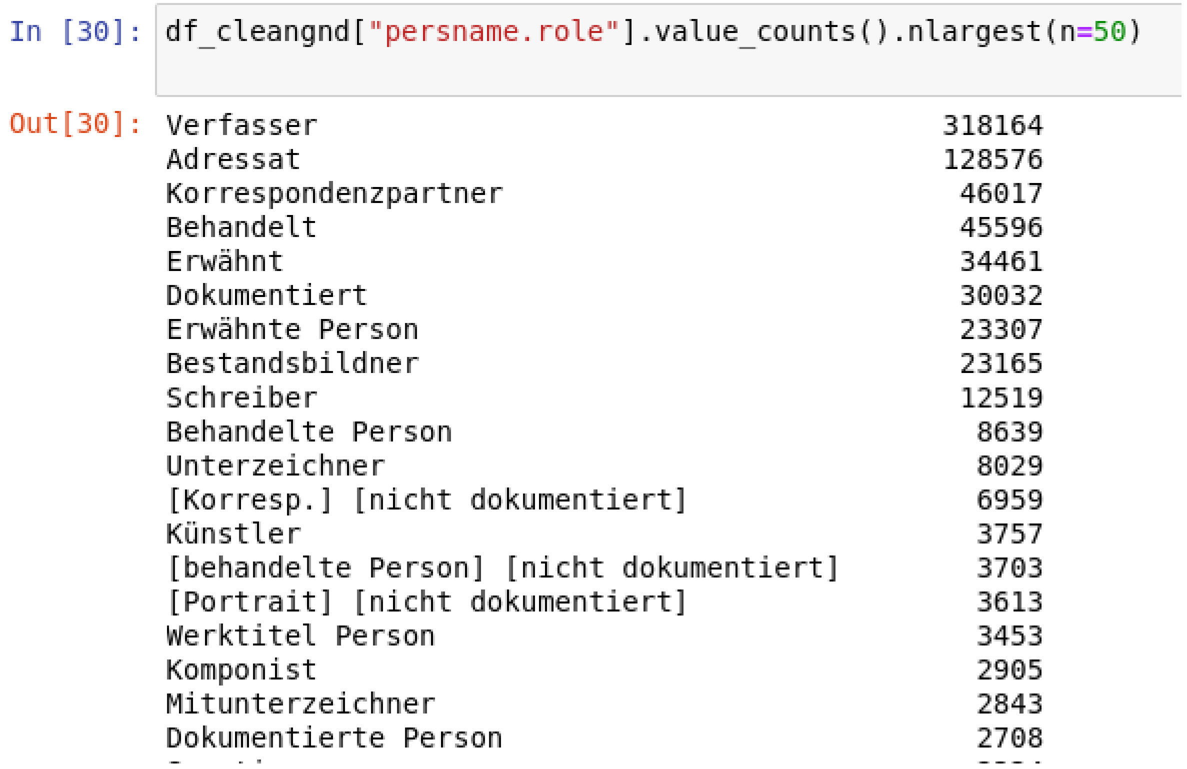

```
In [30]: df_cleangnd["persname.role"].value_counts().nlargest(n=50)

Out[30]: Verfasser                                   318164
         Adressat                                    128576
         Korrespondenzpartner                         46017
         Behandelt                                    45596
         Erwähnt                                      34461
         Dokumentiert                                 30032
         Erwähnte Person                              23307
         Bestandsbildner                              23165
         Schreiber                                    12519
         Behandelte Person                             8639
         Unterzeichner                                 8029
         [Korresp.] [nicht dokumentiert]               6959
         Künstler                                      3757
         [behandelte Person] [nicht dokumentiert]      3703
         [Portrait] [nicht dokumentiert]               3613
         Werktitel Person                              3453
         Komponist                                     2905
         Mitunterzeichner                              2843
         Dokumentierte Person                          2708
```

>persname< in Pandas DataFrame (nach grep, bereinigte Ids): Erstellen eines neuen DataFrames für die vier häufigst vergebenen persname.role Beispiel Adressat

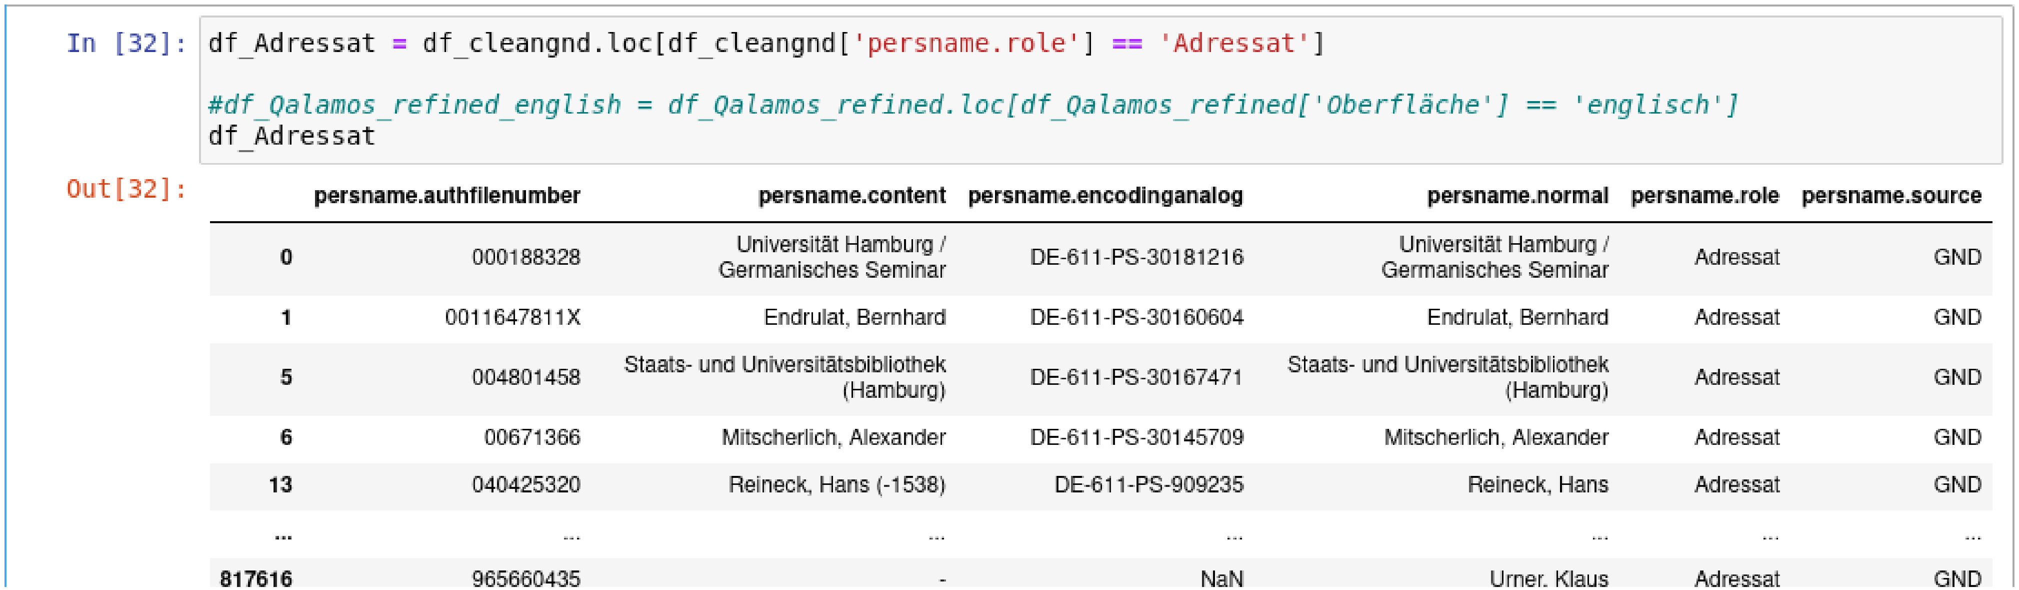

In [32]:
```
df_Adressat = df_cleangnd.loc[df_cleangnd['persname.role'] == 'Adressat']

#df_Qalamos_refined_english = df_Qalamos_refined.loc[df_Qalamos_refined['Oberfläche'] == 'englisch']
df_Adressat
```

Out[32]:

	persname.authfilenumber	persname.content	persname.encodinganalog	persname.normal	persname.role	persname.source
0	000188328	Universität Hamburg / Germanisches Seminar	DE-611-PS-30181216	Universität Hamburg / Germanisches Seminar	Adressat	GND
1	0011647811X	Endrulat, Bernhard	DE-611-PS-30160604	Endrulat, Bernhard	Adressat	GND
5	004801458	Staats- und Universitätsbibliothek (Hamburg)	DE-611-PS-30167471	Staats- und Universitätsbibliothek (Hamburg)	Adressat	GND
6	00671366	Mitscherlich, Alexander	DE-611-PS-30145709	Mitscherlich, Alexander	Adressat	GND
13	040425320	Reineck, Hans (-1538)	DE-611-PS-909235	Reineck, Hans	Adressat	GND
...	...	...	...	...	...	...
817616	965660435	-	NaN	Urner, Klaus	Adressat	GND

>persname< in Pandas DataFrame (nach grep, bereinigte Ids): Erstellen eines neuen DataFrames für die vier häufigst vergebenen persname.role Beispiel Adressat

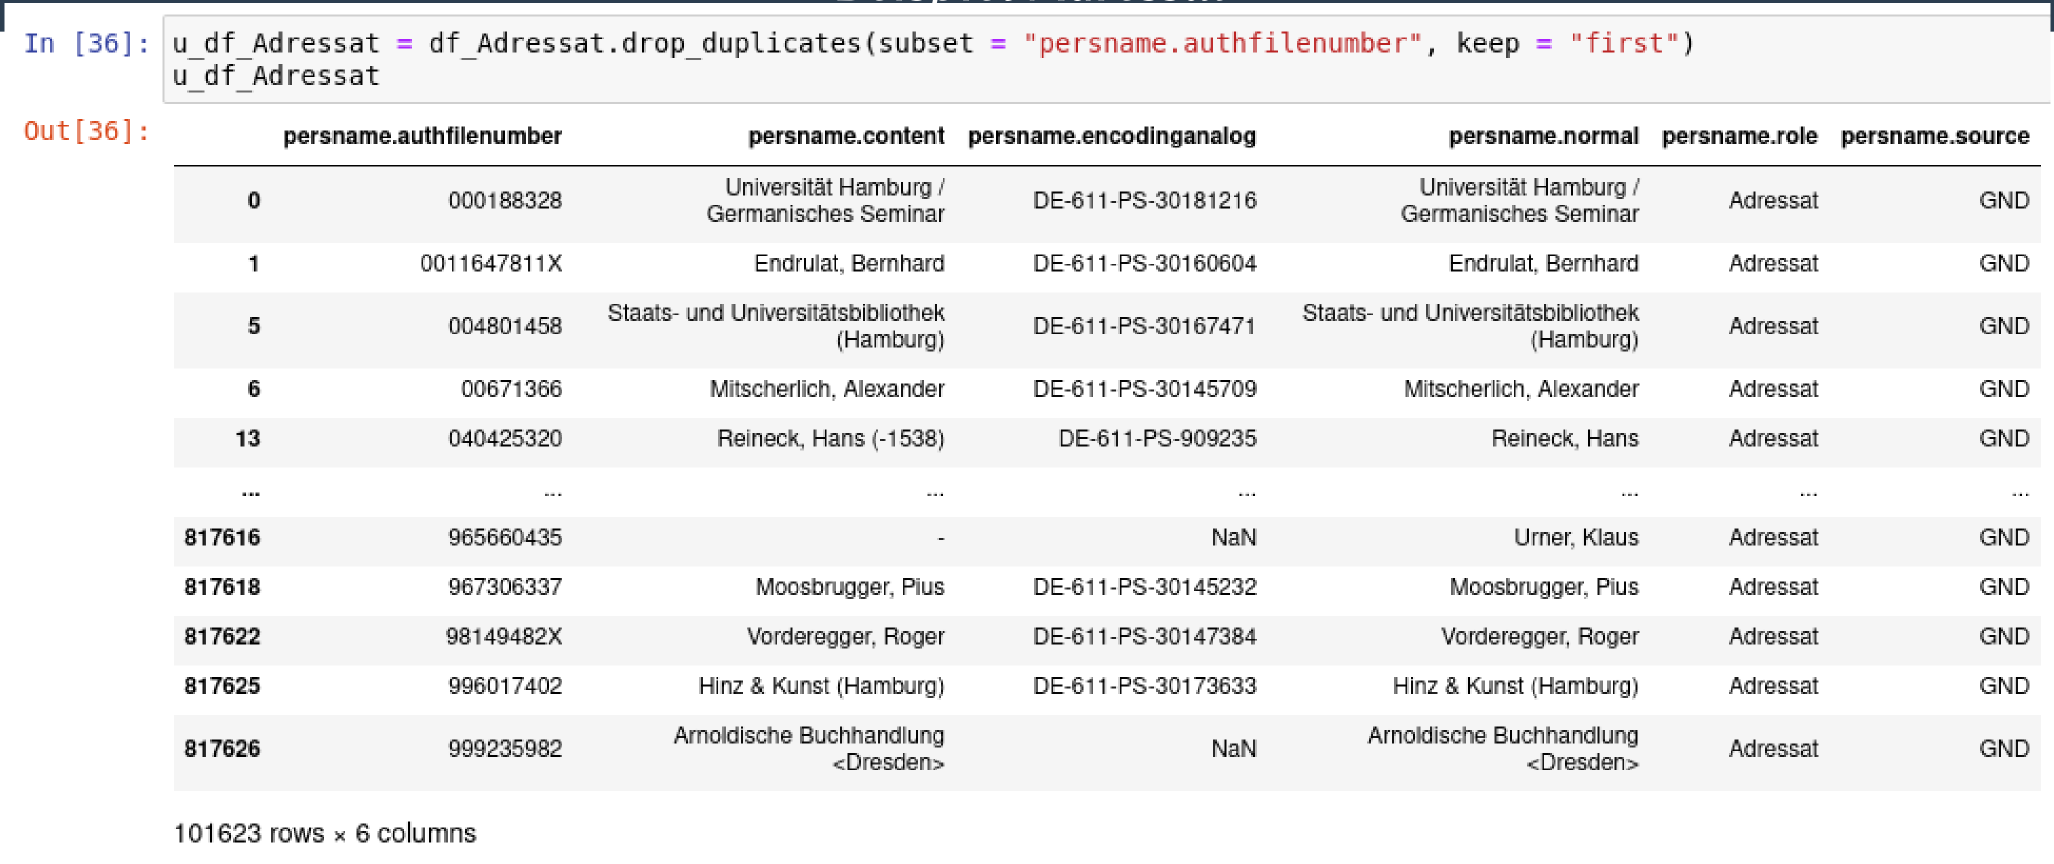

```
In [36]: u_df_Adressat = df_Adressat.drop_duplicates(subset = "persname.authfilenumber", keep = "first")
         u_df_Adressat
```

Out[36]:

	persname.authfilenumber	persname.content	persname.encodinganalog	persname.normal	persname.role	persname.source
0	000188328	Universität Hamburg / Germanisches Seminar	DE-611-PS-30181216	Universität Hamburg / Germanisches Seminar	Adressat	GND
1	0011647811X	Endrulat, Bernhard	DE-611-PS-30160604	Endrulat, Bernhard	Adressat	GND
5	004801458	Staats- und Universitätsbibliothek (Hamburg)	DE-611-PS-30167471	Staats- und Universitätsbibliothek (Hamburg)	Adressat	GND
6	00671366	Mitscherlich, Alexander	DE-611-PS-30145709	Mitscherlich, Alexander	Adressat	GND
13	040425320	Reineck, Hans (-1538)	DE-611-PS-909235	Reineck, Hans	Adressat	GND
...	...	...	...	...	...	...
817616	965660435	-	NaN	Urner, Klaus	Adressat	GND
817618	967306337	Moosbrugger, Pius	DE-611-PS-30145232	Moosbrugger, Pius	Adressat	GND
817622	98149482X	Vorderegger, Roger	DE-611-PS-30147384	Vorderegger, Roger	Adressat	GND
817625	996017402	Hinz & Kunst (Hamburg)	DE-611-PS-30173633	Hinz & Kunst (Hamburg)	Adressat	GND
817626	999235982	Arnoldische Buchhandlung <Dresden>	NaN	Arnoldische Buchhandlung <Dresden>	Adressat	GND

101623 rows × 6 columns

>persname< in Pandas DataFrame (nach grep, bereinigte Ids): Erstellen eines neuen DataFrames für die vier häufigst vergebenen persname.role

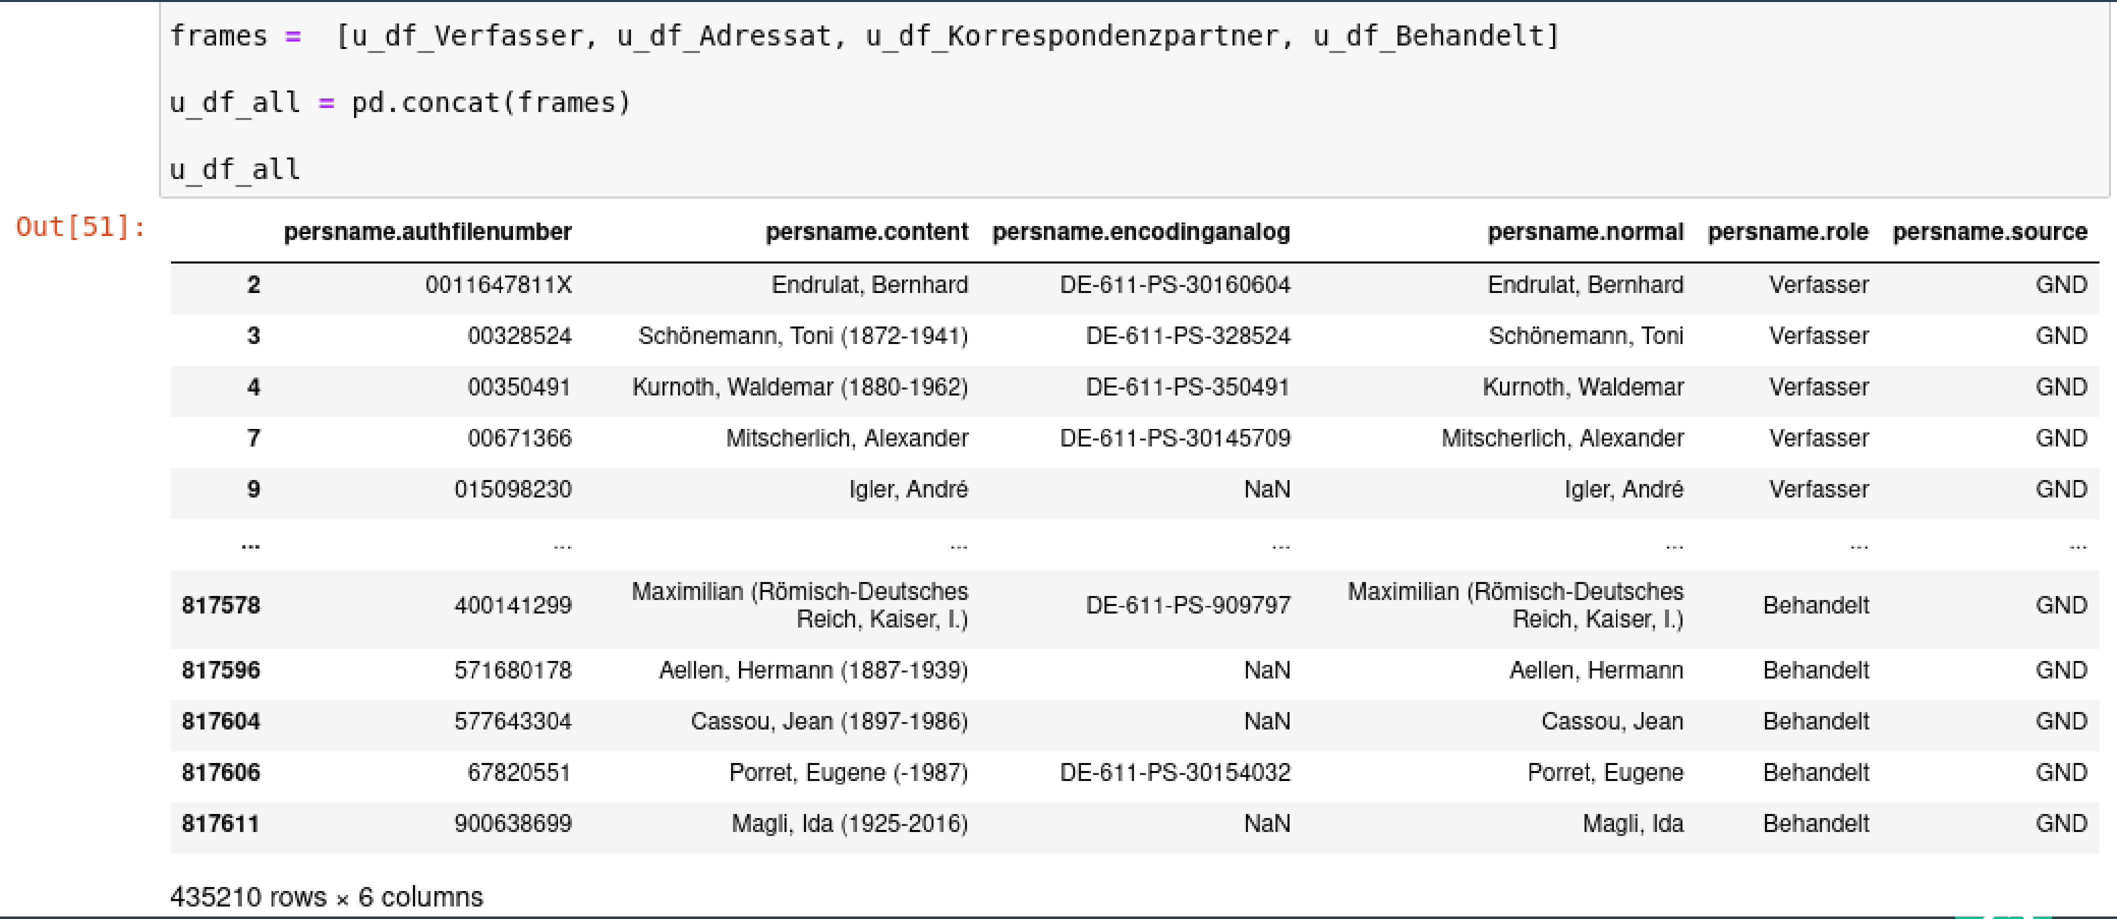

```
frames =  [u_df_Verfasser, u_df_Adressat, u_df_Korrespondenzpartner, u_df_Behandelt]

u_df_all = pd.concat(frames)

u_df_all
```

Out[51]:

	persname.authfilenumber	persname.content	persname.encodinganalog	persname.normal	persname.role	persname.source
2	0011647811X	Endrulat, Bernhard	DE-611-PS-30160604	Endrulat, Bernhard	Verfasser	GND
3	00328524	Schönemann, Toni (1872-1941)	DE-611-PS-328524	Schönemann, Toni	Verfasser	GND
4	00350491	Kurnoth, Waldemar (1880-1962)	DE-611-PS-350491	Kurnoth, Waldemar	Verfasser	GND
7	00671366	Mitscherlich, Alexander	DE-611-PS-30145709	Mitscherlich, Alexander	Verfasser	GND
9	015098230	Igler, André	NaN	Igler, André	Verfasser	GND
...	...	...	...	...	...	...
817578	400141299	Maximilian (Römisch-Deutsches Reich, Kaiser, I.)	DE-611-PS-909797	Maximilian (Römisch-Deutsches Reich, Kaiser, I.)	Behandelt	GND
817596	571680178	Aellen, Hermann (1887-1939)	NaN	Aellen, Hermann	Behandelt	GND
817604	577643304	Cassou, Jean (1897-1986)	NaN	Cassou, Jean	Behandelt	GND
817606	67820551	Porret, Eugene (-1987)	DE-611-PS-30154032	Porret, Eugene	Behandelt	GND
817611	900638699	Magli, Ida (1925-2016)	NaN	Magli, Ida	Behandelt	GND

435210 rows × 6 columns

>persname< in Pandas DataFrame (nach grep, bereinigte Ids): Erstellen eines neuen DataFrames für die vier häufigst vergebenen persname.role

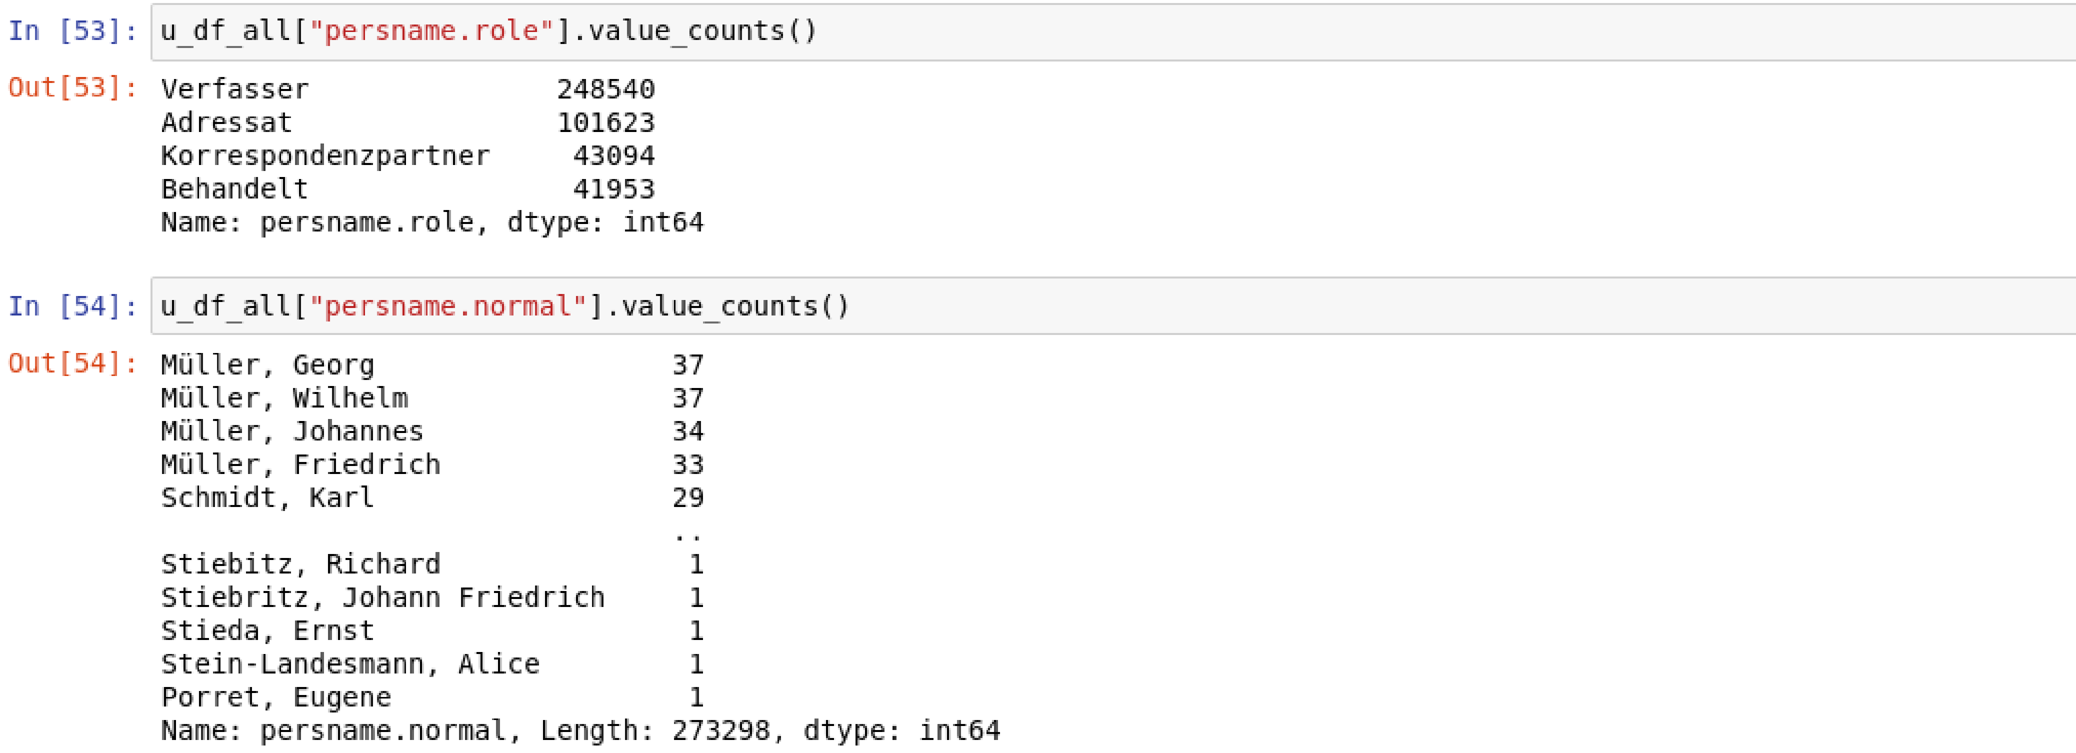

```
In [53]: u_df_all["persname.role"].value_counts()

Out[53]: Verfasser               248540
         Adressat                101623
         Korrespondenzpartner     43094
         Behandelt                41953
         Name: persname.role, dtype: int64

In [54]: u_df_all["persname.normal"].value_counts()

Out[54]: Müller, Georg                  37
         Müller, Wilhelm                37
         Müller, Johannes               34
         Müller, Friedrich              33
         Schmidt, Karl                  29
                                        ..
         Stiebitz, Richard               1
         Stiebritz, Johann Friedrich     1
         Stieda, Ernst                   1
         Stein-Landesmann, Alice         1
         Porret, Eugene                  1
         Name: persname.normal, Length: 273298, dtype: int64
```

>persname< in Pandas DataFrame (nach grep, bereinigte Ids): Erstellen eines neuen DataFrames für die vier häufigst vergebenen persname.role

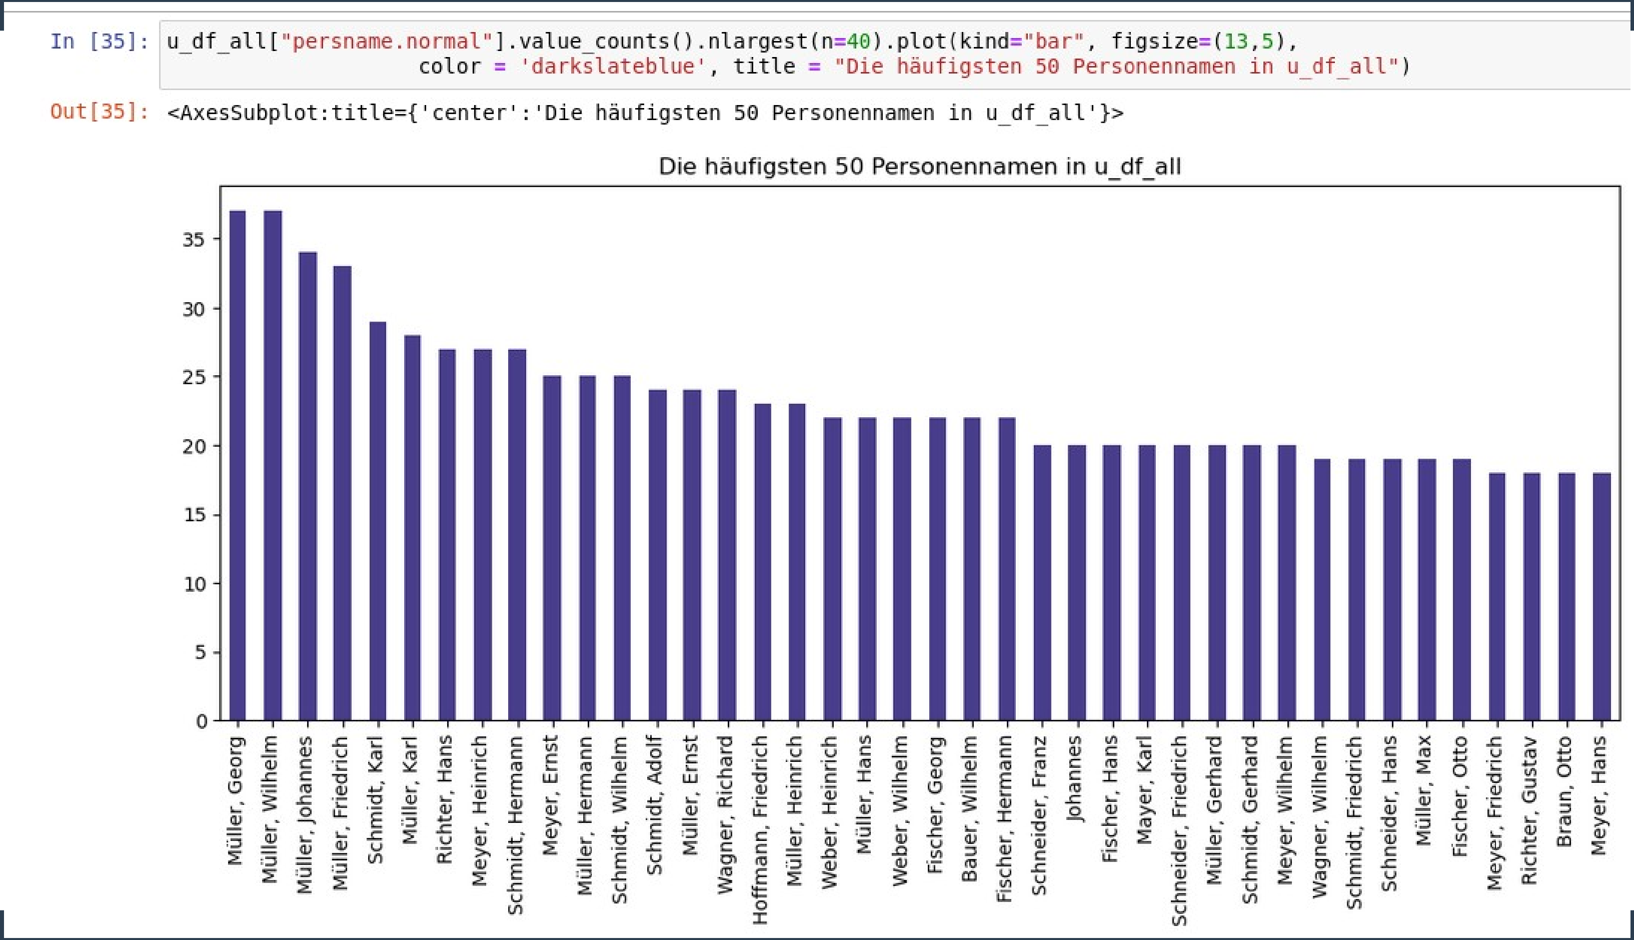

```
In [35]: u_df_all["persname.normal"].value_counts().nlargest(n=40).plot(kind="bar", figsize=(13,5),
                                          color = 'darkslateblue', title = "Die häufigsten 50 Personennamen in u_df_all")

Out[35]: <AxesSubplot:title={'center':'Die häufigsten 50 Personennamen in u_df_all'}>
```

>persname< in Pandas DataFrame (nach grep, bereinigte Ids): Erstellen eines neuen DataFrames für die vier häufigst vergebenen persname.role

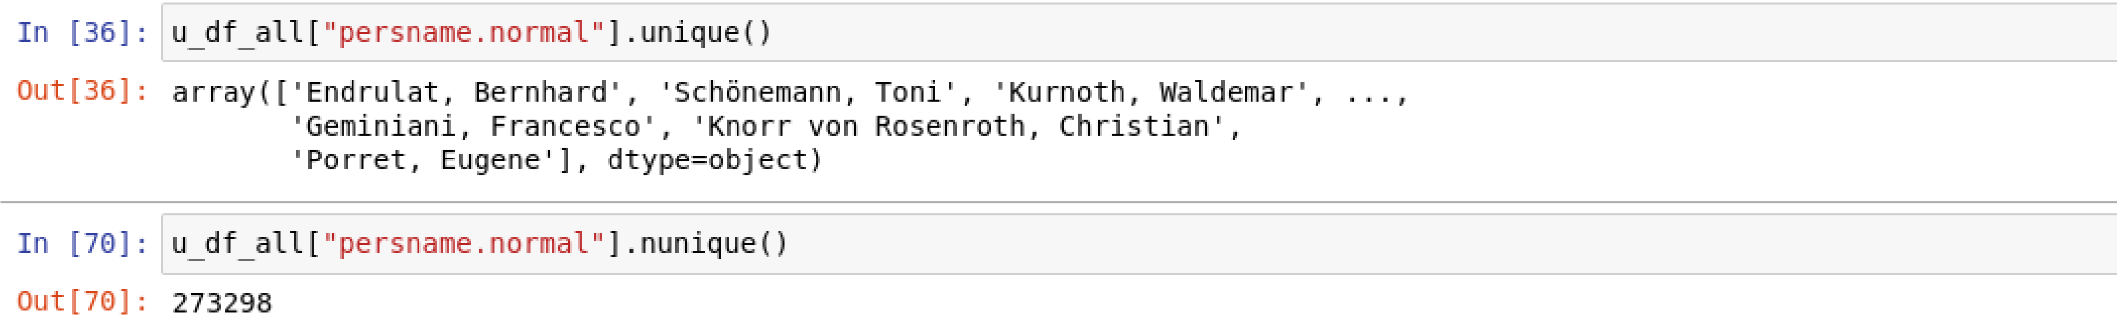

```
In [36]: u_df_all["persname.normal"].unique()

Out[36]: array(['Endrulat, Bernhard', 'Schönemann, Toni', 'Kurnoth, Waldemar', ...,
                'Geminiani, Francesco', 'Knorr von Rosenroth, Christian',
                'Porret, Eugene'], dtype=object)

In [70]: u_df_all["persname.normal"].nunique()

Out[70]: 273298
```

>persname< in Pandas DataFrame (nach grep, bereinigte Ids): Erstellen eines neuen DataFrames für die vier häufigst vergebenen persname.role

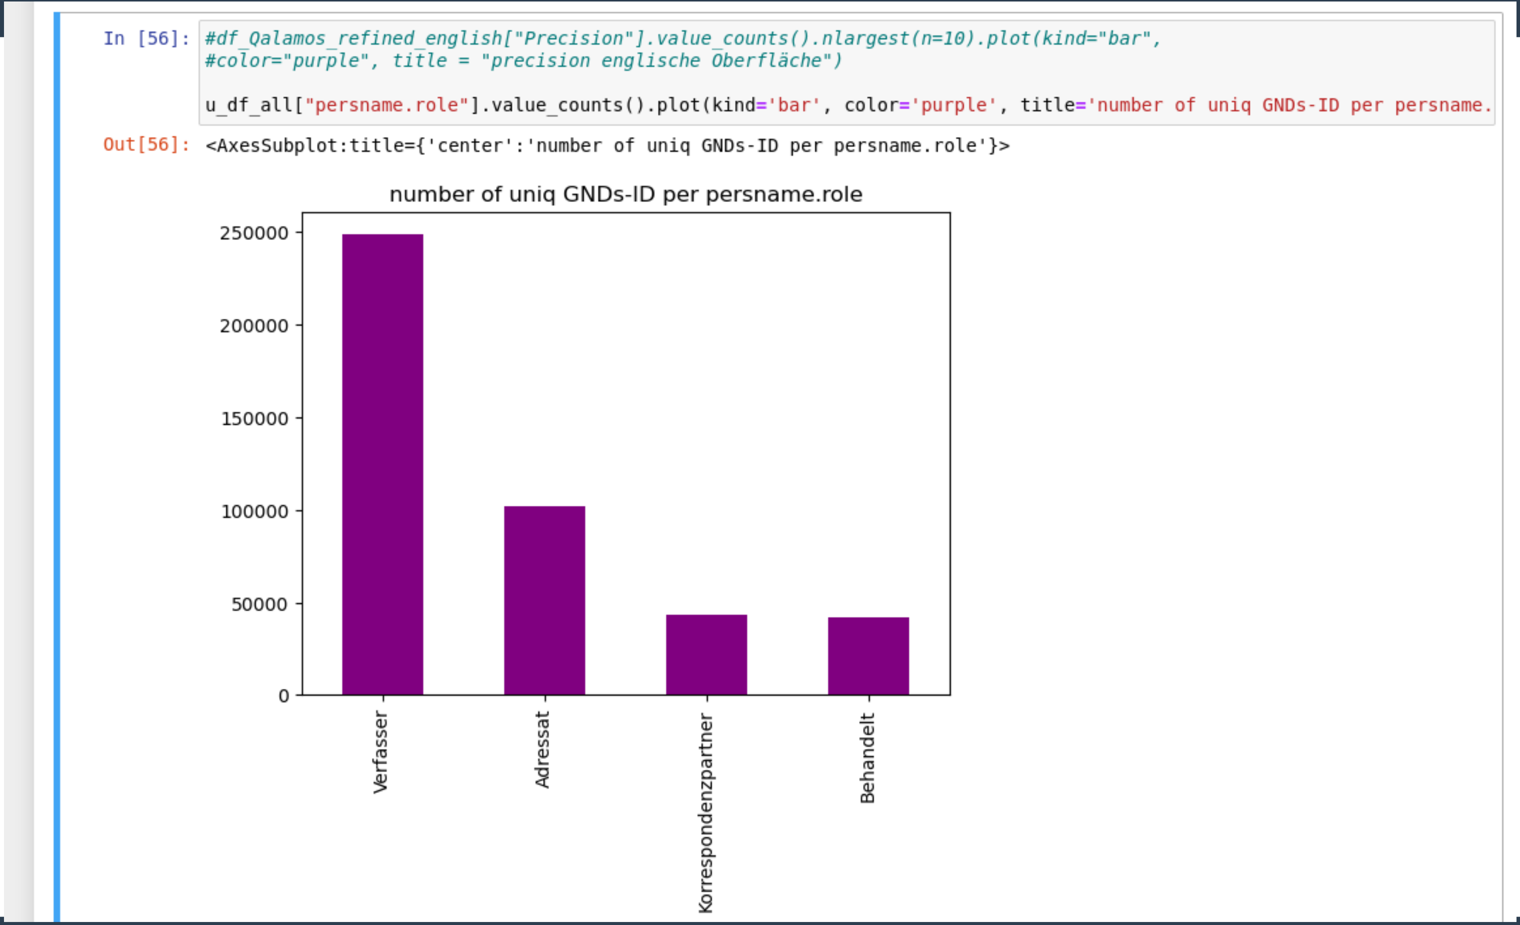

```
In [56]: #df_Qalamos_refined_english["Precision"].value_counts().nlargest(n=10).plot(kind="bar",
         #color="purple", title = "precision englische Oberfläche")

         u_df_all["persname.role"].value_counts().plot(kind='bar', color='purple', title='number of uniq GNDs-ID per persname.

Out[56]: <AxesSubplot:title={'center':'number of uniq GNDs-ID per persname.role'}>
```

>persname< in Pandas DataFrame (nach grep, bereinigte Ids): Erstellen eines neuen DataFrames für die vier häufigst vergebenen persname.role

```
In [60]: df_cleangnd["persname.authfilenumber"].value_counts().nlargest(n=50).plot(kind="bar", figsize=(13,5),
                             color = 'blueviolet', title = "Die 50 häufigsten GND-Ids für Personen")

Out[60]: <AxesSubplot:title={'center':'Die 50 häufigsten GND-Ids für Personen'}>
```

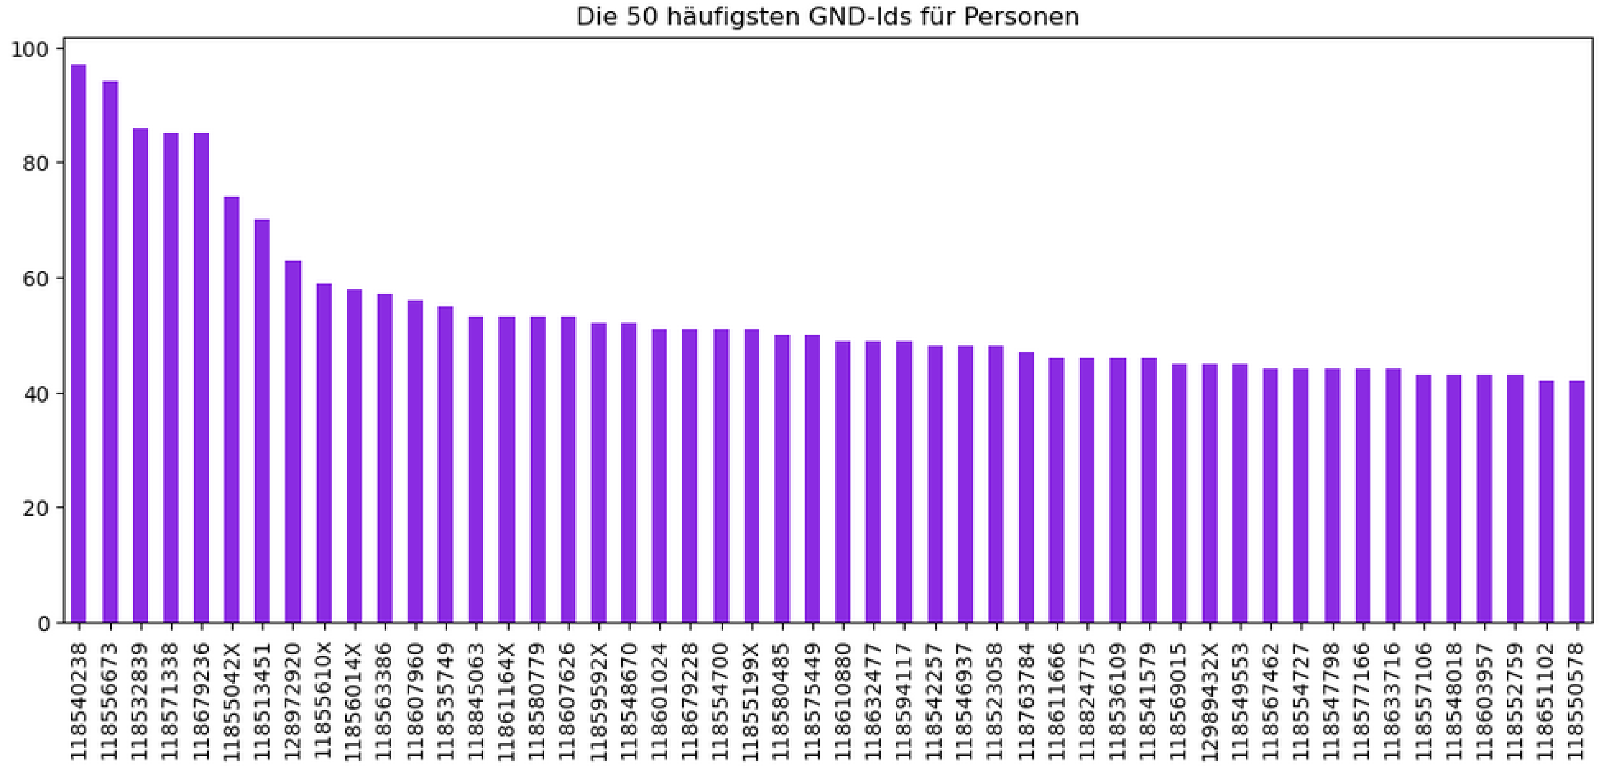

>persname< in Pandas DataFrame (nach grep, bereinigte Ids): Erstellen eines neuen DataFrames für die vier häufigst vergebenen persname.role

sns.catplot(x=more_data_gnd, data=datax, kind='count', aspect = 4) #data = data_gnd,

```
ValueError: The truth value of a Series is ambiguous. Use a.empty, a.bool(), a.item(), a.any() or a.all().
```

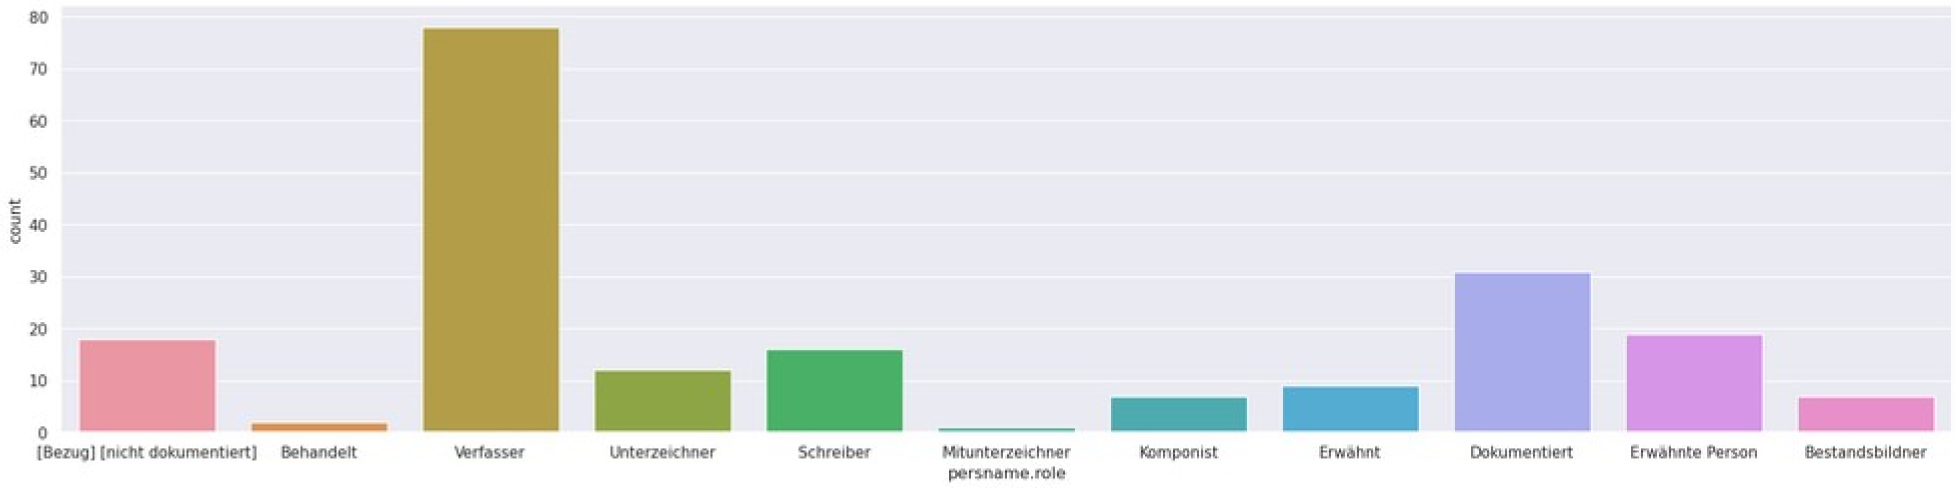

>persname< in Pandas DataFrame (nach grep, bereinigte Ids): Erstellen eines neuen DataFrames für die vier häufigst vergebenen persname.role

```
In [60]: df_cleangnd["persname.authfilenumber"].value_counts().nlargest(n=50).plot(kind="bar", figsize=(13,5),
                                color = 'blueviolet', title = "Die 50 häufigsten GND-Ids für Personen")

Out[60]: <AxesSubplot:title={'center':'Die 50 häufigsten GND-Ids für Personen'}>
```

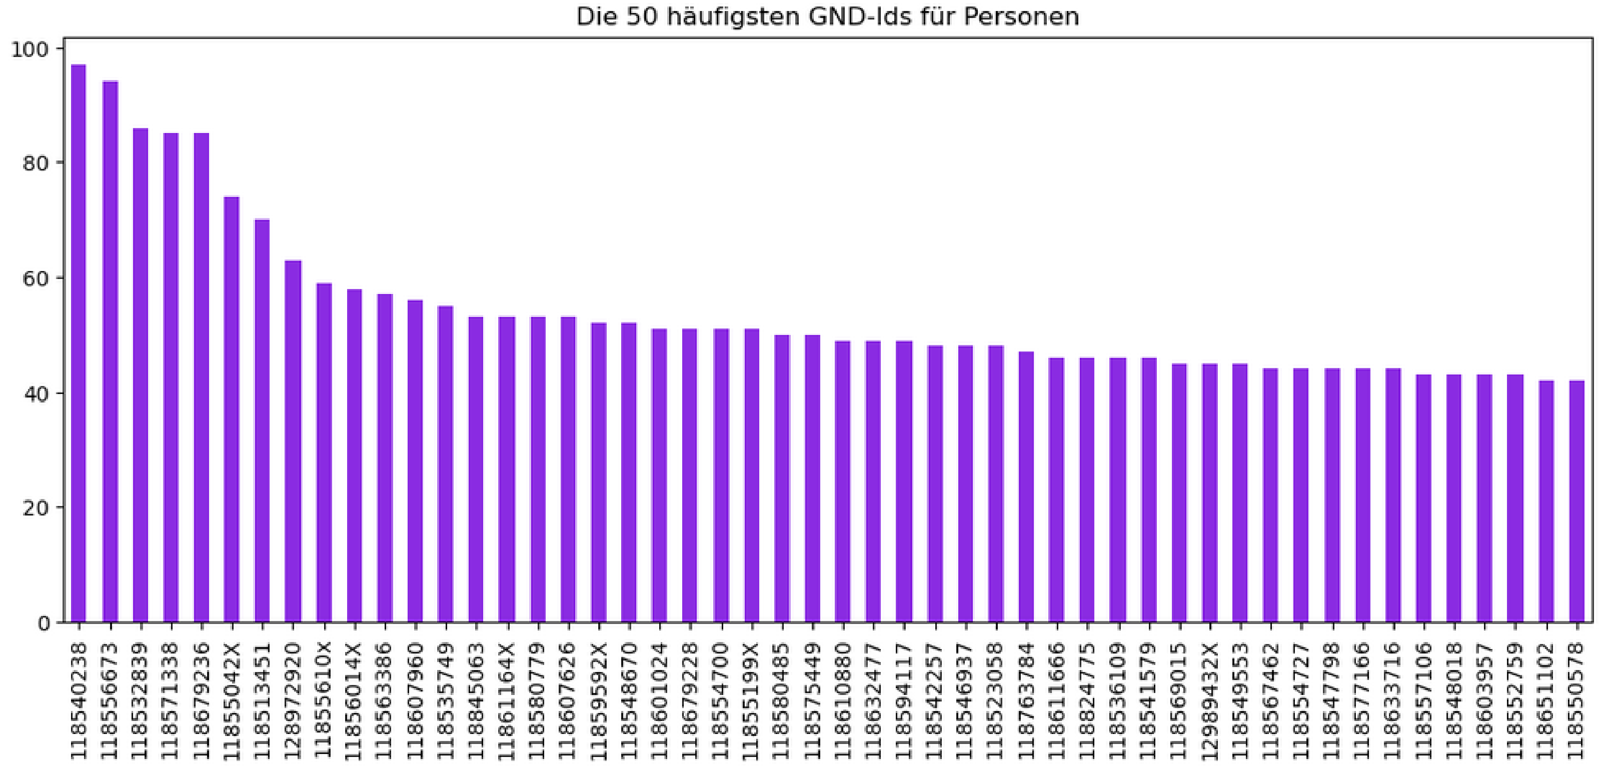

Vielen Dank!